Universidad Nacional de Córdoba

Facultad de Matemática, Astronomía, Física y Computación

Análisis multiespectral de imágenes Sentinel-2 para la detección automática de áreas irrigadas por pivotes centrales

por

Maria Victoria Lopez Amuchastegui

Presentado ante la **FACULTAD DE MATEMÁTICA, ASTRONOMÍA, FÍSICA Y COMPUTACIÓN** como parte de los requerimientos para la obtención del grado de Licenciado en ciencias de la computación de la

UNIVERSIDAD NACIONAL DE CÓRDOBA

Julio, 2026

Directores: Mg. Axel Waldemar Elseser & Dr. Juan Bautista Cabral

Análisis multiespectral de imágenes Sentinel-2 para la detección automática de áreas irrigadas por pivotes centrales© 2026
by Maria Victoria Lopez Amuchastegui
is licensed under
Creative Commons Attribution-ShareAlike 4.0 International

Certifico que el trabajo incluido en este documento es el resultado de tareas de investigación originales y que no ha sido presentado para optar a un título en ninguna otra Universidad o Institución.

Agradecimientos

Quiero expresar mi sincero agradecimiento a todas las personas e instituciones que hicieron posible la realización de este trabajo.

En primer lugar, a mis directores, el Dr. Juan Bautista Cabral y el Mg. Axel Waldemar Elseser, por su acompañamiento constante, su guía académica y su compromiso a lo largo de todo el proceso de investigación. Sus aportes, observaciones y sugerencias fueron fundamentales para el desarrollo y la consolidación de esta tesis.

A la Universidad Nacional de Córdoba y, en particular, a la Facultad de Matemática, Astronomía, Física y Computación, por brindarme una formación académica de excelencia y un entorno que promovió mi crecimiento intelectual y personal.

A mis compañeros y amigos de carrera, Tomás, Franco, Lautaro, Guillermo, Pedro, Alejo y Antonella, por las risas, el apoyo y los innumerables momentos compartidos durante estos años de formación. Haber transitado este camino junto a ustedes hizo que cada desafío fuera más llevadero.

A mi familia y a las personas cercanas que me acompañaron durante todo este recorrido, por su apoyo incondicional, su confianza y su estímulo permanente.

En especial, a mis padres, Jorgelina y Federico, por sostenerme en cada etapa de mi formación. Su esfuerzo, su confianza en mí y su presencia constante fueron un pilar fundamental para alcanzar esta meta.

A mis abuelos, por haberme acompañado siempre, por su ayuda y por el cariño que me impulsó a seguir adelante incluso en los momentos más difíciles. Su apoyo fue una parte esencial de este camino.

Finalmente, a todas las personas que, de una u otra manera, contribuyeron a que este proyecto pudiera concretarse.

Resumen

Esta tesis evalúa el rendimiento de distintas combinaciones espectrales de imágenes Sentinel-2 para la detección automática de áreas irrigadas mediante sistemas de riego por pivote central. El estudio se desarrolló en la provincia de Córdoba durante la campaña primavera–verano 2023–2024, utilizando modelos de segmentación basados en aprendizaje profundo.

Se generaron cuatro composiciones espectrales: color natural (B4, B3, B2), bordes rojos (B7, B6, B5), falso color (B8A, B4, B3) y SWIR (B11, B8, B4), y se entrenó el modelo YOLO11s-seg de manera independiente sobre cada una de ellas. El dataset fue construido mediante un proceso semiautomático que integró Grounding DINO, SAM y validación geoespacial en QGIS.

La evaluación se realizó mediante curvas Precisión–Recall bajo distintos umbrales de IoU y con análisis de precisión a recall fijo. Los resultados muestran que todas las composiciones espectrales presentan un desempeño similar bajo criterios geométricos moderados (IoU ≤ 0.85), alcanzando altos niveles de precisión al recuperar el 80 % de los pivotes reales. Sin embargo, cuando se exige una coincidencia espacial más estricta (IoU ≥ 0.90), surgen diferencias significativas, destacándose la composición SWIR y, en menor medida, las bandas de borde rojo.

En conjunto, el estudio demuestra que la información espectral no afecta sustancialmente la capacidad de detección del modelo, pero sí influye en la precisión geométrica de la segmentación.

Abstract

This thesis evaluates the performance of different spectral combinations of Sentinel-2 imagery for the automatic detection of irrigated areas using center-pivot irrigation systems. The study was conducted in the province of Córdoba during the 2023–2024 spring–summer season, using deep learning–based segmentation models.

Four spectral compositions were generated: natural color (B4, B3, B2), red edge (B7, B6, B5), false color (B8A, B4, B3), and SWIR (B11, B8, B4). The YOLO11s-seg model was trained independently on each of these compositions. The dataset was constructed through a semi-automatic process that integrated Grounding DINO, SAM, and geospatial validation in QGIS.

The evaluation was carried out using Precision–Recall curves under different IoU thresholds and through precision analysis at fixed recall. The results show that all spectral compositions exhibit similar performance under moderate geometric criteria (IoU ≤ 0.85), achieving high precision levels while recovering 80 % of real pivots. However, when stricter spatial agreement is required (IoU ≥ 0.90), significant differences emerge, with the SWIR composition standing out and, to a lesser extent, the red-edge bands.

Overall, the study demonstrates that spectral information does not substantially affect the model's detection capability, but it does influence the geometric precision of the segmentation.

Glosario

AR Automatización del Riego 4, 5

BB Bounding Box ..... 20, 21, 26, 33, 34, XIII

CM matriz de confusión 22, 23

COP Copernicus 3, 14

CV Computer Vision 19, 21, 33, 35

ESA Agencia Espacial Europea 3, 14

FAO Food and Agriculture Organization 4

FN Falso negativo 22–25

FP Falso positivo 22–27

GDAL Geospatial Data Abstraction Library 35

GEE Google Earth Engine 28, 32, 37

GeoTIFF Geographic Tagged Image File Format 32, 34, 38–40

GPKG GeoPackage 36

IA Inteligencia Artificial 3, 17

INTA Instituto Nacional de Tecnología Agropecuaria 8

IoU Intersection over Union ..... 3, 26, 27, 42–52, 54, VIII, IX, XIII, XIV

MSI Multispectral Instrument ..... 14, 15, 17, XII

NDVI Normalized Difference Vegetation Index 16, 17

NIR Near Infrared ..... 2, 11–16, 30, 31, XI

No Skill No Skill ..... 25, XII

PR Precisión–Recall ..... 3, 25, 26, 42, 44, 46, 48, 51, XII–XIV

PREC Precision ..... 23–27, 42–52, 54, XII–XIV

QGIS Quantum Geographic Information System ..... 3, 35, 36, XIII

REC Recall ..... 23–27, 42–52, 54, IX, XII–XIV

REM radiación electromagnética 10

S2 Sentinel-2 ..... 3, 13–17, 28–35, 37, XII, XIII

SAM Segment Anything Model ..... 3, 34, 35, 37, 38, XIII

SAR Synthetic Aperture Radar 13

SIG Sistemas de Información Geográfica 3, 32, 34, 35, 38

SR Sensado Remoto 3, 10, 13, 14, 16–18

SRPC Sistema de riego de pivote central 7, 8, 16, 17, 28, 29

SWIR Shortwave Infrared .. 2, 3, 11–14, 16, 30, 32, 44–52, 54, XI, XIII, XIV

VIS Visible 14, 15

VN Verdadero negativo 22, 23

VP Verdadero positivo 22–27

YOLO You Only Look Once ..... 3, 21, 22, 37–40, XIII

YOLO11s-seg YOLO11s Segmentation 3, 21

YOLOv8-seg YOLOv8 Segmentation 21

YOLOv9-seg YOLOv9 Segmentation 21

Índice general

Agradecimientos **I**

Resumen **III**

Abstract **IV**

Glosario **VII**

Índice de figuras **XI**

Índice de código **XVI**

1. Introducción **2**
1.1. Organización del trabajo 3

2. Antecedentes **4**
2.1. El Riego 4
2.2. Automatización del Riego 5
2.3. Pivotes de riego 8
2.4. Sensado Remoto 10
2.4.1. Sentinel-2 14
2.5. Gran volumen de datos 16
2.6. Aprendizaje automático 17
2.7. Segmentación 19
2.8. Métricas 22
2.8.1. Matriz de confusión 22
2.8.2. (Intersection over Union (IoU)) 26

3. Procesamiento De Datos **28**
3.1. Bandas Espectrales de Sentinel-2 28
3.2. Grounding DINO 32
3.3. Uso de QGIS para el análisis y organización de la información espacial 35
3.4. Generación de anotaciones YOLO 38
3.5. División de datos en *folds* de entrenamiento y validación 39

4. Resultados **42**
4.1. Visión general de los resultados 42
4.2. Análisis por umbral de IoU 42
4.3. Análisis por composición espectral 44
4.4. Análisis con Recall (REC) fijo 47
4.4.1. Precisión en función del umbral de IoU 47
4.4.2. Análisis por composición espectral con REC fijo en 0.80 . 49

5. Conclusiones y trabajo a futuro **53**
5.1. Trabajo a Futuro 54

Bibliografía **57**

Índice de figuras

2.1. Cultivo intensivo con sistema de riego por goteo automatizado. Se observan hileras de plantas dispuestas en surcos paralelos, junto con mangueras negras ubicadas a nivel del suelo que recorren cada fila. A través de estas líneas de goteo, los emisores suministran agua de manera controlada directamente en la base de cada planta. Adaptado de (Wikipedia contributors, 2025). 6
2.2. Ejemplo de riego por microaspersión automatizado en un cultivo frutal. Se observan hileras de árboles jóvenes con dispositivos emisores ubicados a baja altura, los cuales proyectan chorros de agua en forma de abanico sobre el suelo circundante, generando una cobertura localizada alrededor de cada planta. (Nelson Irrigation Corporation, 2025). 7
2.3. Ejemplo de riego por aspersión automatizado en un cultivo agrícola. Se observan aspersores distribuidos a lo largo del terreno que proyectan chorros de agua en arcos superpuestos, generando una cobertura uniforme sobre las hileras de cultivo. Fuente: Puroxi (2025). 7
2.4. Sistema de riego por pivote central automatizado: (a) vista a nivel de campo y (b) vista aérea que evidencia la escala y geometría del sistema.(AGRIVI, 2025; ResearchGate, 2020). 8
2.5. Esquema general de un sistema de riego por pivote central y sus principales componentes estructurales. Elaboración de (Irrifrance, sf). 9
2.6. Ejemplo de composiciones RGB generadas a partir de una misma imagen satelital. Fuente: adaptado de Geoinnova (2020). 12
2.7. Firmas espectrales del agua, el suelo desnudo y la vegetación en el visible, Near Infrared (NIR) y Shortwave Infrared (SWIR): la curva azul corresponde al agua, la curva marrón/roja al suelo desnudo y la curva verde a la vegetación. Fuente: Lillesand et al. (2015). 13
2.8. Ejemplo de representación de datos hiperespectrales. A la izquierda se observa la organización de la información en capas apiladas según la longitud de onda, mientras que a la derecha se muestra la respuesta espectral asociada a un punto de la imagen. Fuente: adaptado de Bannon (2009). 14

2.9. Distribución espectral y resolución espacial de las bandas del sensor Multispectral Instrument (MSI) de Sentinel-2 (S2). Cada rectángulo coloreado representa una de las 13 bandas espectrales del sensor, cuya posición indica el intervalo de longitudes de onda que abarca y cuya altura se relaciona con su resolución espacial. Adaptado de Drusch et al. (2012a) y (Cursos Teledetección, 2020). 15
2.10. Comparación entre clasificación de imágenes, segmentación semántica, detección de objetos y segmentación de instancias. Adaptado de una imagen disponible en línea. 20
2.11. Matriz de confusión y relación entre valores reales y valores predichos. Adaptado de Barrios (2020). 23
2.12. Representación geométrica de la relación entre precisión y recall. El rectángulo verde representa el conjunto de elementos realmente relevantes, mientras que el círculo representa los elementos recuperados por el modelo. La intersección entre ambos conjuntos corresponde a los verdaderos positivos; los elementos recuperados que no son relevantes corresponden a los falsos positivos; y los elementos relevantes que no fueron recuperados corresponden a los falsos negativos. 24
2.13. Ejemplo de curva Precisión–Recall (Precisión–Recall (PR)), donde se muestra la relación entre la Precision (PREC) (eje vertical) y el REC (eje horizontal) para distintos umbrales de decisión. La curva azul representa el desempeño del modelo evaluado, mientras que la línea punteada corresponde a la referencia No Skill (No Skill) de un clasificador sin capacidad predictiva. Los puntos numerados indican distintos escenarios de funcionamiento: (1) alta precisión con bajo recall, (2) comportamiento ideal con precisión y recall máximos, (3) alto recall con pérdida de precisión y (4) un punto intermedio de compromiso entre ambas métricas. 25
2.14. Esquema del cálculo de Intersección sobre Unión (IoU) entre la región real del objeto y la región predicha por el modelo. 27

3.1. Imagen S2 en color natural (B4, B3, B2) correspondiente a la provincia de Córdoba. Los contornos negros son anotaciones superpuestas que delimitan parcelas circulares identificadas como áreas bajo riego por pivote central. Imagen generada a partir de datos Sentinel-2 procesados en Google Earth Engine. 29
3.2. Imagen S2 utilizando la combinación de bordes rojos (B7, B6, B5) correspondiente a la provincia de Córdoba. Los contornos negros son anotaciones superpuestas que delimitan parcelas circulares identificadas como áreas bajo riego por pivote central. Imagen generada a partir de datos Sentinel-2 procesados en Google Earth Engine. 30
3.3. Imagen S2 en falso color SWIR (B11, B8, B4) correspondiente a la provincia de Córdoba. Los contornos negros son anotaciones superpuestas que delimitan parcelas circulares identificadas como áreas bajo riego por pivote central. Imagen generada a partir de datos Sentinel-2 procesados en Google Earth Engine. 31

3.4. Imagen S2 en falso color infrarrojo (B8A, B4, B3) correspondiente a la provincia de Córdoba. Los contornos negros son anotaciones superpuestas que delimitan parcelas circulares identificadas como áreas bajo riego por pivote central. Imagen generada a partir de datos Sentinel-2 procesados en Google Earth Engine. 32
3.5. Detección automática de pivotes de riego mediante Grounding DINO sobre una imagen S2 en composición falso color. Los recuadros de colores corresponden a las Bounding Box (BB) generadas por el modelo para delimitar posibles áreas irrigadas por pivote central. Las etiquetas indican la clase predicha y el valor de confianza asociado a cada detección. 34
3.6. Máscara binaria de pivotes obtenida mediante la integración Grounding DINO–Segment Anything Model (SAM). Los píxeles blancos representan las regiones identificadas como áreas pertenecientes a pivotes de riego, mientras que los píxeles negros corresponden al fondo o zonas no detectadas. 34
3.7. Visualización en Quantum Geographic Information System (QGIS) de la capa combinada, utilizada para contrastar resultados parciales provenientes de distintos parches o configuraciones. Las regiones en gris corresponden a las máscaras generadas para las áreas identificadas como pivotes de riego. 36
3.8. Visualización en QGIS de la capa unida, correspondiente al producto vectorial maestro que consolida las detecciones de pivotes de riego. Las regiones verdes representan detecciones provenientes de una capa de entrada, mientras que las regiones rojas corresponden a detecciones incorporadas desde otras capas durante el proceso de combinación. 36
3.9. Tabla de atributos de la *capa unida*, donde se observan los campos de identificación y trazabilidad asociados a cada detección. . . . 37
3.10. Ejemplo de anotaciones en formato You Only Look Once (YOLO) generadas a partir de las geometrías vectoriales de pivotes de riego. Cada objeto se representa mediante un conjunto de coordenadas normalizadas que describen el contorno del pivote dentro del parche satelital correspondiente. 39
3.11. Pipeline completo de procesamiento de datos, detección, segmentación, etiquetado y validación 41

4.1. Curvas PR comparadas por umbral de IoU para distintas composiciones espectrales. Cada panel corresponde a un umbral de evaluación diferente: IoU $\geq$ 0.75 en el panel superior izquierdo, IoU $\geq$ 0.80 en el panel superior derecho, IoU $\geq$ 0.85 en el panel inferior izquierdo e IoU $\geq$ 0.90 en el panel inferior derecho. El eje horizontal representa el REC y el eje vertical la PREC. Los colores identifican las composiciones espectrales evaluadas: azul para color natural, naranja para bordes rojos, verde para SWIR y rojo para falso color. Los estilos de línea identifican el umbral de IoU: línea continua para 0.75, línea discontinua para 0.80, línea punto-raya para 0.85 y línea punteada para 0.90. 44

4.2. Curvas PR por composición espectral, comparando distintos umbrales de IoU. Cada panel corresponde a una composición espectral diferente: color natural en el panel superior izquierdo, bordes rojos en el panel superior derecho, SWIR en el panel inferior izquierdo y falso color en el panel inferior derecho. El eje horizontal representa el REC y el eje vertical la PREC. Los colores identifican la composición espectral de cada panel: azul para color natural, naranja para bordes rojos, verde para SWIR y rojo para falso color. Los estilos de línea representan los distintos umbrales de IoU: línea continua para 0.75, línea discontinua para 0.80, línea punto-raya para 0.85 y línea punteada para 0.90. 46
4.3. Curvas PR comparadas por umbral de IoU con REC fijo en 0.80. Cada panel corresponde a un umbral de evaluación diferente: IoU $\geq$ 0.75 en el panel superior izquierdo, IoU $\geq$ 0.80 en el panel superior derecho, IoU $\geq$ 0.85 en el panel inferior izquierdo e IoU $\geq$ 0.90 en el panel inferior derecho. El eje horizontal representa el REC y el eje vertical la PREC. Los colores identifican las composiciones espectrales evaluadas: azul para color natural, naranja para bordes rojos, verde para SWIR y rojo para falso color. Los estilos de línea identifican el umbral de IoU: línea continua para 0.75, línea discontinua para 0.80, línea punto-raya para 0.85 y línea punteada para 0.90. La línea vertical gris marca el valor de REC = 0.80 utilizado para comparar la precisión entre configuraciones. 48
4.4. Curvas PR por composición espectral con REC fijo en 0.80. Cada panel corresponde a una composición espectral diferente: color natural en el panel superior izquierdo, bordes rojos en el panel superior derecho, SWIR en el panel inferior izquierdo y falso color en el panel inferior derecho. El eje horizontal representa el REC y el eje vertical la PREC. Los colores identifican la composición espectral de cada panel: azul para color natural, naranja para bordes rojos, verde para SWIR y rojo para falso color. Los estilos de línea representan los distintos umbrales de IoU: línea continua para 0.75, línea discontinua para 0.80, línea punto-raya para 0.85 y línea punteada para 0.90. La línea vertical gris marca el valor de REC = 0.80 utilizado para comparar la precisión entre configuraciones. 51

Índice de códigos

3.2.1.Parámetros y consultas textuales utilizados en Grounding DINO 33

Capítulo 1

Introducción

El riego por pivote central es un sistema mecanizado de aspersión que distribuye el agua en un patrón circular alrededor de un punto fijo. Este método es ampliamente utilizado en la agricultura debido a su eficiencia en el uso del agua y a su elevada capacidad de automatización. Entre sus principales ventajas se encuentra la posibilidad de regular el caudal aplicado en función de las necesidades del cultivo y de las condiciones del suelo, lo que optimiza el uso del recurso hídrico. Además, los pivotes centrales reducen significativamente la necesidad de supervisión permanente, disminuyendo los costos operativos y garantizando una cobertura uniforme del riego (Herrera and Correa, 2005).

El mapeo y monitoreo de las áreas irrigadas mediante estos sistemas resulta fundamental, ya que permite analizar la distribución espacial del riego y apoyar una gestión más eficiente de los recursos hídricos disponibles (Saraiva et al., 2020).

Identificar de manera sistemática los pivotes centrales es fundamental, especialmente en áreas donde la alta concentración de sistemas de riego puede generar una presión excesiva sobre las reservas de agua subterránea, comprometiendo su disponibilidad a largo plazo y afectando distintos usos del recurso (FAO, 2011; Scanlon et al., 2012).

Para la detección de estas estructuras es posible emplear imágenes satelitales provenientes de la misión Sentinel-2, compuesta por satélites gemelos que operan en órbitas sincronizadas con un desfase de 180°. Esta configuración proporciona una resolución temporal de 10 días por satélite, o de aproximadamente 5 días en conjunto, lo que habilita un monitoreo casi continuo de la superficie terrestre.

Las imágenes de Sentinel-2 están formadas por 13 bandas espectrales que abarcan desde el espectro visible hasta el infrarrojo de onda corta (*Short-Wave Infrared*, Shortwave Infrared (SWIR)), cubriendo aproximadamente un rango de longitudes de onda entre 443 nm y 2190 nm. El sensor incluye bandas específicamente diseñadas para el monitoreo de la vegetación, como la banda roja (B4, 665 nm), el infrarrojo cercano (Near Infrared (NIR); B8, 842 nm) y las bandas del borde rojo (*red edge*; B5, B6 y B7), ubicadas aproximadamente entre 705 nm y 783 nm. Estas bandas resultan especialmente útiles para caracterizar áreas agrícolas y detectar patrones asociados al riego debido a su sensibilidad frente al contenido de clorofila, la estructura de la vegetación y la humedad de los cultivos. La resolución espacial varía según la banda: las bandas del visible y del infrarrojo cercano presentan una resolución de 10 m; las bandas del

SWIR cuentan con una resolución de 20 m; y las bandas destinadas a corrección atmosférica poseen una resolución de 60 m (Phiri et al., 2020).

Para la identificación automática de objetos en imágenes satelitales se emplean técnicas de aprendizaje profundo basadas en redes neuronales convolucionales. Entre los modelos más utilizados se destaca You Only Look Once (YOLO), un algoritmo de código abierto diseñado para la detección de objetos en tiempo real mediante una única red neuronal convolucional (Pérez et al., 2019). YOLO divide la imagen de entrada en una cuadrícula y predice simultáneamente múltiples regiones candidatas, optimizando el proceso de detección.

La arquitectura original del modelo cuenta con 24 capas convolucionales destinadas a la extracción de características, seguidas por dos capas completamente conectadas que generan las predicciones finales. Asimismo, incorpora convoluciones de reducción 1×1 combinadas con convoluciones 3×3 para mejorar la eficiencia computacional. La salida del modelo se representa mediante un tensor de dimensiones $7 \times 7 \times 30$, donde cada celda almacena información asociada a la presencia, localización y clase de los objetos detectados (Cifuentes et al., 2019).

En este trabajo se propone evaluar el rendimiento de distintas combinaciones de bandas espectrales para la detección de áreas irrigadas por pivotes centrales, utilizando imágenes multiespectrales del satélite Sentinel-2 (S2) (misión Copernicus (COP) de la Agencia Espacial Europea (ESA)).

1.1. Organización del trabajo

Los capítulos de este trabajo se organizan de la siguiente manera:

En el Capítulo 2 se presentan los fundamentos teóricos que sustentan esta investigación. Se describen los sistemas de riego, con énfasis en el riego por pivote central, su relevancia para la gestión de recursos hídricos y la importancia de su detección. Además, se introducen conceptos de Sensado Remoto (SR), la misión S2, Inteligencia Artificial (IA), técnicas de segmentación de instancias y las métricas de evaluación utilizadas.

El Capítulo 3 documenta el procesamiento de datos llevado a cabo para la construcción del dataset. Se detalla la generación de composiciones espectrales a partir de imágenes S2, el uso de Grounding DINO (modelo de detección de objetos basado en IA) y Segment Anything Model (SAM) (modelo de segmentación basado en IA) para la detección y segmentación semiautomática de pivotes, la validación geoespacial mediante Quantum Geographic Information System (QGIS) (software de Sistemas de Información Geográfica (SIG)), la generación de anotaciones en formato YOLO (formato de etiquetas para entrenamiento de modelos de detección de objetos) y la división de los datos en folds de entrenamiento y validación.

En el Capítulo 4 se presentan los resultados obtenidos en términos de curvas Precisión–Recall (PR) bajo distintos umbrales de Intersection over Union (IoU) y análisis de precisión a recall fijo, comparando el desempeño del modelo YOLO11s Segmentation (YOLO11s-seg) sobre las cuatro composiciones espectrales evaluadas.

Finalmente, las conclusiones generales son presentadas en el Capítulo 5, donde también se discuten posibles líneas futuras de desarrollo.

Capítulo 2

Antecedentes

2.1. El Riego

El riego es una de las prácticas agrícolas más antiguas y su función principal consiste en proporcionar agua de manera controlada a los cultivos cuando las precipitaciones naturales resultan insuficientes. Es un factor clave para la producción agrícola, ya que permite estabilizar los rendimientos, mejorar la eficiencia en el uso del agua y contribuir a la sostenibilidad de los sistemas productivos. Entre sus principales ventajas se destacan la provisión adecuada de agua para el crecimiento de las plantas, la reducción de los efectos negativos de la variabilidad climática, la facilitación de la absorción de nutrientes por parte de las raíces, la regulación del microclima del cultivo y la mejora tanto en la cantidad como en la calidad de la producción (Cortijo, 2001). Desde la antigüedad, el riego ha cumplido un rol central en la transformación de los paisajes y en la organización de las sociedades. Civilizaciones como Mesopotamia, Egipto, el valle del Indo y China desarrollaron sistemas de canales aprovechando las crecidas de los ríos, lo que permitió convertir regiones áridas en áreas productivas y generar excedentes agrícolas que impulsaron el comercio. Con el paso del tiempo, se incorporaron otras soluciones hidráulicas —como los acueductos romanos, las acequias medievales y los qanats persas— adaptadas a las condiciones geográficas y climáticas de cada región (Food and Agriculture Organization of the United Nations, 2021).

En la actualidad, el riego no debe entenderse únicamente como una respuesta a la falta de lluvias, sino como un instrumento estratégico para sostener y mejorar la producción agrícola. En un contexto de cambio climático, caracterizado por una mayor frecuencia e intensidad de sequías, los sistemas de riego cumplen un papel fundamental al proteger a los cultivos frente al déficit hídrico, reduciendo la vulnerabilidad de los sistemas productivos y aumentando su resiliencia. Su relevancia no se limita al aspecto técnico, sino que también se extiende a dimensiones económicas, sociales y ambientales, consolidándolo como un componente central de la agricultura moderna, en línea con las recomendaciones de la Food and Agriculture Organization (FAO) (Food and Agriculture Organization of the United Nations, 2021).

En tiempos más recientes, los avances tecnológicos han posibilitado el desarrollo de sistemas de riego más eficientes, como los sistemas de Automatización

del Riego (AR), que optimizan la distribución del agua mediante el uso de sensores y mecanismos de control automático (Cortijo, 2001).

2.2. Automatización del Riego

La AR es una de las innovaciones más importantes de la agricultura actual, sobre todo en un contexto donde el agua es un recurso cada vez más limitado. Este enfoque combina componentes electrónicos, sensores y procesamiento de datos en tiempo real para que el riego funcione de manera automática, reduciendo la necesidad de intervención constante por parte del productor. A través de válvulas controladas electrónicamente, el sistema ajusta variables como la presión, la frecuencia de riego y el volumen de agua aplicado según las características de cada sector del lote, lo que permite disminuir errores operativos y mejorar la precisión en el uso del recurso hídrico (Cortijo, 2001).

La AR puede aplicarse a distintos métodos de riego —como goteo, aspersión o microaspersión— y adaptarse tanto a explotaciones extensivas como a superficies de menor escala, sin requerir necesariamente grandes cambios en la infraestructura existente. Esta flexibilidad explica su creciente adopción en sistemas productivos diversos y en regiones con condiciones climáticas variables.

La principal diferencia con los sistemas tradicionales está en la precisión. Mientras que el riego convencional depende en gran medida de la experiencia y el criterio del productor, los sistemas automatizados aplican agua en función de las necesidades reales del cultivo. Para ello, se apoyan en sensores de humedad del suelo, tensiómetros, estaciones meteorológicas y caudalímetros, que registran de forma continua variables como el contenido de agua en el suelo, la radiación solar, la temperatura y las condiciones atmosféricas. A partir de esto, el sistema activa o detiene el riego según parámetros predefinidos o modelos de decisión, evitando tanto excesos como déficits hídricos, mejorando la eficiencia en el uso del agua y reduciendo pérdidas por escurrimiento o percolación profunda (Food and Agriculture Organization of the United Nations, 2021).

Estos beneficios se reflejan tanto en el plano productivo como en el ambiental. Desde lo económico, la automatización reduce la variabilidad propia del manejo manual, mejora la uniformidad en el desarrollo del cultivo y contribuye a estabilizar los rendimientos, especialmente en especies sensibles al estrés hídrico. Desde una mirada ambiental, ayuda a prevenir procesos de degradación del suelo, como la salinización y la acumulación de sales en el perfil edáfico, problemas frecuentes cuando el volumen de agua aplicado no se controla adecuadamente (Montesinos et al., 2007).

Tipos de riego automatizado

La AR puede implementarse sobre distintos sistemas de riego:

- **Riego por goteo automatizado:** Aplica el agua de manera localizada directamente en la zona de las raíces mediante emisores de bajo caudal. La automatización permite regular con gran precisión la frecuencia y la duración del riego, optimizando el uso del agua y los nutrientes. Como

se observa en la Figura 2.1, este sistema se caracteriza por una aplicación altamente eficiente, por lo que es ampliamente utilizado en cultivos intensivos, frutales y horticultura.

Figura 2.1: Cultivo intensivo con sistema de riego por goteo automatizado. Se observan hileras de plantas dispuestas en surcos paralelos, junto con mangueras negras ubicadas a nivel del suelo que recorren cada fila. A través de estas líneas de goteo, los emisores suministran agua de manera controlada directamente en la base de cada planta. Adaptado de (Wikipedia contributors, 2025).

- **Riego por microaspersión automatizado:** Utiliza emisores que distribuyen el agua en forma de pequeñas gotas sobre áreas reducidas. La automatización mejora la uniformidad de aplicación y permite ajustar el riego según las condiciones climáticas. Como se puede ver en la Figura 2.2, este sistema se emplea con frecuencia en frutales y viveros, donde además contribuye a regular el microclima y a reducir el estrés hídrico.

Figura 2.2: Ejemplo de riego por microaspersión automatizado en un cultivo frutal. Se observan hileras de árboles jóvenes con dispositivos emisores ubicados a baja altura, los cuales proyectan chorros de agua en forma de abanico sobre el suelo circundante, generando una cobertura localizada alrededor de cada planta. (Nelson Irrigation Corporation, 2025).

- **Riego por aspersión automatizado:** Simula la lluvia mediante aspersores distribuidos en el lote. En los sistemas automatizados se controlan la presión, el caudal y los tiempos de riego, logrando una aplicación más homogénea que en los sistemas manuales. En la Figura 2.3 vemos que se trata de un método versátil, utilizado tanto en cultivos extensivos como intensivos.

Figura 2.3: Ejemplo de riego por aspersión automatizado en un cultivo agrícola. Se observan aspersores distribuidos a lo largo del terreno que proyectan chorros de agua en arcos superpuestos, generando una cobertura uniforme sobre las hileras de cultivo. Fuente: Puroxi (2025).

- **Riego por pivote central automatizado:** Los sistemas de riego por pivote central Sistema de riego de pivote central (SRPC) son una de las formas más difundidas de riego a presión automatizado en grandes superficies agrícolas. La automatización permite regular la velocidad de avance,

el caudal aplicado y, en configuraciones más avanzadas, la dosificación variable del agua. Este tipo de riego combina una alta uniformidad de aplicación, facilidad de control y costos operativos relativamente bajos, lo que explica su amplia adopción en la agricultura moderna.

La Figura 2.4 permite visualizar este sistema en funcionamiento y su impacto sobre el terreno desde distintas perspectivas.

Imagen (a)

Imagen (b)

Figura 2.4: Sistema de riego por pivote central automatizado: (a) vista a nivel de campo y (b) vista aérea que evidencia la escala y geometría del sistema.(AGRIVI, 2025; ResearchGate, 2020).

2.3. Pivotes de riego

Los SRPC constituyen una de las configuraciones tecnológicas más difundidas dentro de los sistemas de riego a presión en la agricultura moderna. Su desarrollo se remonta a mediados del siglo XX en Estados Unidos, a partir de la patente presentada por Frank Zybach en 1952, en un contexto de creciente mecanización agrícola y de necesidad de optimizar el uso del agua en explotaciones de gran escala. Desde entonces, su adopción se expandió a nivel internacional, consolidándose como una solución eficiente para el riego de parcelas extensas y de geometría regular (Agrivi, 2020).

En Argentina, la incorporación de pivotes centrales se intensificó a partir de la década de 1990, favorecida por la disponibilidad de tecnologías importadas, el acceso a recursos hídricos subterráneos y los resultados obtenidos en ensayos técnicos realizados por el Instituto Nacional de Tecnología Agropecuaria (INTA) Manfredi, que validaron su desempeño agronómico y económico en condiciones locales (Instituto Nacional de Tecnología Agropecuaria, 2011; Martellotto et al., 2005).

El rasgo distintivo de estos sistemas es la aplicación de agua mediante un movimiento circular continuo alrededor de un punto fijo, lo que permite cubrir grandes superficies con un patrón espacial regular y fácilmente identificable, tal como se ilustra en la Figura 2.4. Esta disposición influye tanto en la eficiencia hidráulica del sistema como en la organización del espacio productivo, facilitando la planificación y el manejo de los cultivos.

El funcionamiento del pivote central se basa en la integración de componentes mecánicos e hidráulicos diseñados para garantizar la estabilidad estructural,

el desplazamiento controlado y la distribución uniforme del agua. Entre los principales elementos que conforman el sistema se destacan (véase Figura 2.5):

- **Tramos**: secciones estructurales tubulares que conforman el cuerpo principal del pivote (representados en color verde). Conectan la torre central con las torres móviles y sostienen la tubería de conducción de agua y los aspersores.
- **Acoplamientos**: elementos de unión entre tramos (indicados en color naranja) que permiten el ensamblaje modular del sistema. Facilitan el montaje, desmontaje y mantenimiento, además de absorber pequeñas desalineaciones durante el movimiento.
- **Torre**: estructura vertical que soporta los tramos y alberga el sistema de transmisión del movimiento (representada en color azul). Cada torre mantiene la alineación del pivote y garantiza un avance sincronizado.
- **Ruedas motrices**: ubicadas en la base de las torres (también en color azul), son las encargadas de impulsar el desplazamiento lento y continuo del sistema, permitiendo completar el recorrido circular del riego.
- **Voladizo**: tramo final del pivote que se extiende más allá de la última torre móvil (representado en color violeta). Su función es aumentar el radio de cobertura del riego sin necesidad de incorporar una torre adicional.
- **Pirámide**: estructura de soporte situada en el extremo del sistema (indicada en color rojo). Contribuye a la estabilidad del voladizo y al equilibrio estructural general del pivote.
- **Caño principal (no dibujado)**: tubería que recorre los tramos y transporta el agua desde la torre central hasta los aspersores distribuidos a lo largo del sistema.

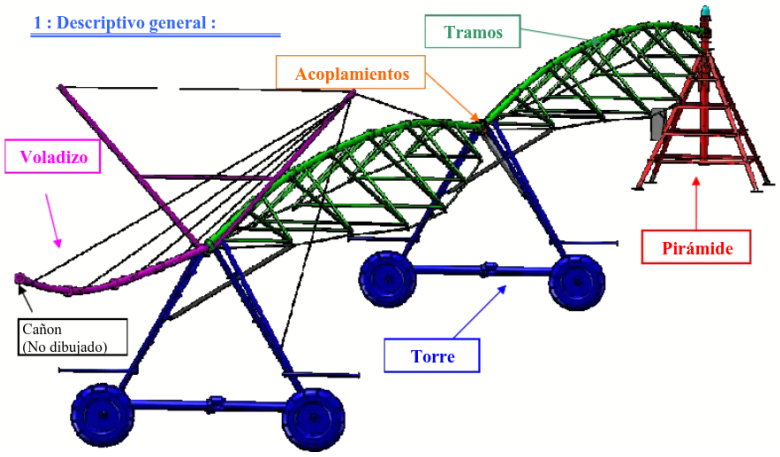

Figura 2.5: Esquema general de un sistema de riego por pivote central y sus principales componentes estructurales. Elaboración de (Irrifrance, sf).

La combinación de estos componentes posibilita altos niveles de uniformidad en la aplicación del agua y un control preciso del avance del sistema, lo que explica su amplia adopción en la agricultura extensiva. En comparación con otros métodos de riego a presión, el pivote central presenta una relación favorable entre superficie cubierta, requerimientos operativos y costos de mantenimiento, especialmente cuando se implementa en parcelas de gran tamaño y geometría regular.

Más allá de su eficiencia productiva, los pivotes centrales generan impactos claramente visibles sobre el paisaje agrario, principalmente a partir de la huella circular que dejan sobre el territorio. Esta característica facilita la identificación de las áreas irrigadas y permite analizar procesos de intensificación agrícola, expansión del riego y cambios en el uso del suelo, lo que los convierte en objetos de interés no solo desde el punto de vista agronómico, sino también desde perspectivas territoriales y ambientales. En particular, su geometría regular y su alta contrastabilidad respecto del entorno los convierten en estructuras especialmente adecuadas para ser identificadas mediante técnicas de análisis espacial y teledetección, lo que refuerza el interés en su estudio sistemático.

En este contexto, el reconocimiento y monitoreo de los pivotes de riego mediante técnicas de sensado remoto adquiere especial relevancia, ya que la identificación de su localización y evolución temporal permite estimar la superficie efectivamente irrigada, evaluar la presión sobre acuíferos y suelos y comprender la dinámica de los sistemas productivos. Las imágenes satelitales se presentan, en este sentido, como una herramienta clave para la detección sistemática de estas estructuras, el seguimiento de su expansión y la generación de información estratégica para la gestión del riego, la planificación territorial y el diseño de políticas públicas orientadas a la sostenibilidad (Food and Agriculture Organization of the United Nations, 2021).

2.4. Sensado Remoto

El Sensado Remoto (SR) se define como el proceso mediante el cual se adquiere información de un objeto, área o fenómeno sin contacto físico directo, mediante el uso de sensores que registran la radiación electromagnética (REM) reflejada o emitida por la superficie terrestre. Esta información se obtiene considerando la interacción de la radiación con la atmósfera, la cual puede absorber, dispersar o transmitir la energía en distintas regiones del espectro electromagnético antes de que sea registrada por el sensor (Camacho-Velasco, 2015).

El SR consiste en analizar cómo interactúa la REM con los objetos. Cada material posee una firma espectral, entendida como el patrón característico de reflectancia y absorción en distintas longitudes de onda. En otras palabras, se trata de la "huella digital" que deja cada objeto cuando la radiación incidente interactúa con su superficie. Este comportamiento refleja distintas características físicas, entre ellas el contenido de agua, la estructura celular de la vegetación, la composición mineral y el estado térmico de los materiales.

La información registrada por los sensores se materializa, entre otros productos, en imágenes satelitales, representaciones espaciales compuestas por píxeles, donde cada píxel almacena valores de reflectancia medidos en distintas bandas del espectro electromagnético (Richards, 2013). A partir de estas imágenes es posible generar combinaciones de bandas, conocidas como composiciones RGB,

que permiten visualizar una misma escena de distintas maneras según las coberturas o procesos que se busque resaltar.

La Figura 2.6 ejemplifica este principio mediante dos composiciones: en el panel superior se presenta una imagen en color natural, en la que las bandas correspondientes al espectro visible (rojo: $\sim$0.63–0.69 μm; verde: $\sim$0.53–0.59 μm; azul: $\sim$0.45–0.52 μm) se asignan directamente a los canales RGB, reproduciendo una representación visual similar a la percepción del ojo humano; mientras que en el panel inferior se muestra una composición en falso color RGB 8-4-3 (donde el número 8 corresponde a la banda del infrarrojo cercano, el 4 a la banda roja y el 3 a la banda verde), en la cual el Near Infrared (NIR) se asigna al canal rojo. Bajo esta configuración, la vegetación se representa en tonos rojizos intensos, lo que incrementa el contraste con otras coberturas y facilita la identificación de superficies cultivadas y de patrones circulares característicos del riego por pivote central (Geoinnova, 2020).

La interpretación de estas composiciones se fundamenta en el comportamiento espectral de las coberturas. La vegetación sana presenta una alta reflectancia en el NIR debido a la estructura interna de las hojas, mientras que el agua exhibe valores de reflectancia muy bajos tanto en el espectro visible como en el infrarrojo cercano, producto de su elevada absorción de energía. Por su parte, el Shortwave Infrared (SWIR) es particularmente sensible al contenido de humedad, lo que permite resaltar diferencias hídricas y aumentar la separabilidad espectral entre superficies con distinta disponibilidad de agua (Lillesand et al., 2015).

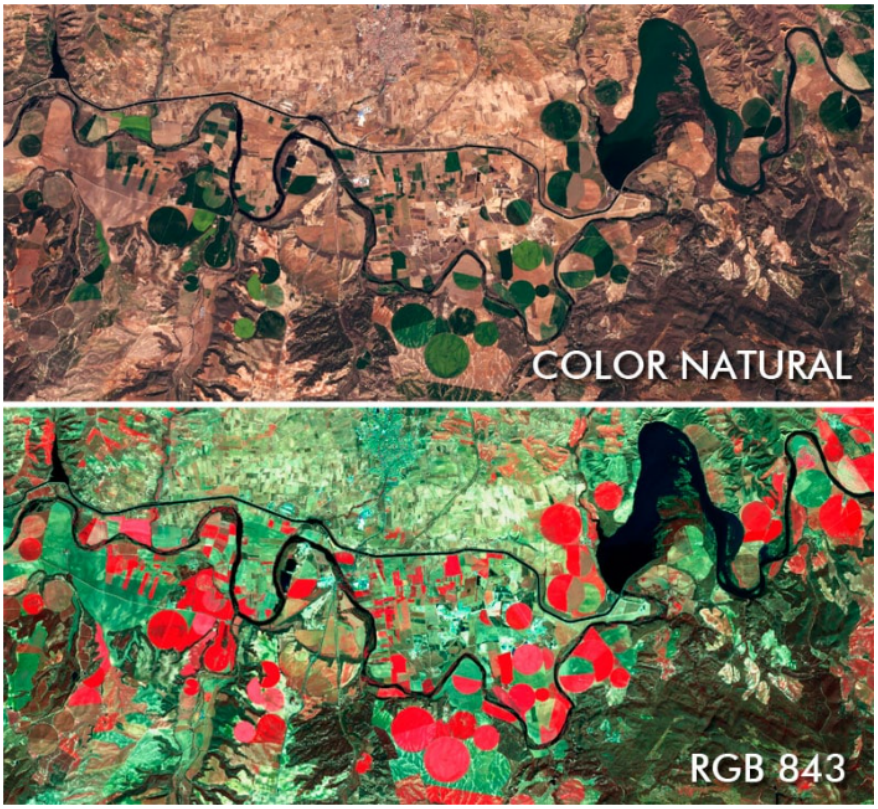

Figura 2.6: Ejemplo de composiciones RGB generadas a partir de una misma imagen satelital. Fuente: adaptado de Geoinnova (2020).

Estas respuestas espectrales se sintetizan en la Figura 2.7, donde se representan las firmas típicas de la vegetación (curva verde), el suelo (curva roja) y el agua (curva azul). En el pasaje del visible al NIR, la vegetación evidencia un incremento abrupto de la reflectancia, conocido como *red edge*, mientras que el agua mantiene valores bajos en todo ese rango espectral. En el SWIR, la reflectancia de la vegetación disminuye a medida que aumenta su contenido de humedad, lo cual se observa en la Figura 2.7 como una depresión o descenso de la curva verde en ese rango espectral. Este comportamiento se debe a la mayor absorción del agua en estas longitudes de onda y contrasta con el del suelo, cuya reflectancia presenta una variación más gradual. Estas diferencias explican la utilidad de determinadas bandas y combinaciones espectrales para la discriminación de coberturas y el análisis de variables biofísicas (Lillesand et al., 2015).

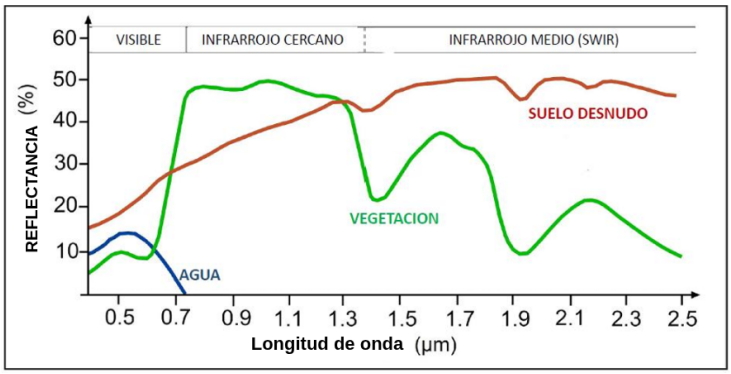

Figura 2.7: Firmas espectrales del agua, el suelo desnudo y la vegetación en el visible, NIR y SWIR: la curva azul corresponde al agua, la curva marrón/roja al suelo desnudo y la curva verde a la vegetación. Fuente: Lillesand et al. (2015).

Desde el punto de vista instrumental, los sensores de SR se clasifican en pasivos y activos. Los sensores pasivos dependen de la energía solar y registran la radiación reflejada, siendo los más comunes en misiones ópticas como Landsat o Sentinel-2 (S2) (Lillesand et al., 2015; Drusch et al., 2012b). En cambio, los sensores activos emiten su propia energía y registran la señal retrodispersada; un ejemplo representativo es el radar de apertura sintética (Synthetic Aperture Radar (SAR)), capaz de operar de noche y bajo condiciones de nubosidad (Jensen, 2015). El desempeño de estos sistemas depende de parámetros técnicos como la resolución espacial, espectral, temporal y radiométrica (Richards, 2013).

En particular, la resolución espectral permite distinguir entre imágenes multiespectrales e hiperespectrales. Las imágenes multiespectrales registran la radiación en un número limitado de bandas de ancho espectral del orden de decenas a cientos de nanómetros (por ejemplo, entre $\sim$20 y 200 nm), y constituyen la base de sensores ampliamente utilizados, como S2, Landsat 8/9 o PlanetScope (Phiri et al., 2020). Por el contrario, las imágenes hiperespectrales capturan cientos de bandas estrechas y contiguas, generando un espectro casi continuo por píxel y representable como un cubo tridimensional (Figura 2.8), donde el panel (a) ilustra el cubo de datos con dos dimensiones espaciales (x, y) y una dimensión espectral (λ), mientras que el panel (b) muestra la firma espectral asociada a un píxel específico. Esta representación permite una identificación más precisa de materiales y coberturas (Camacho-Velasco, 2015; Thenkabail et al., 2012).

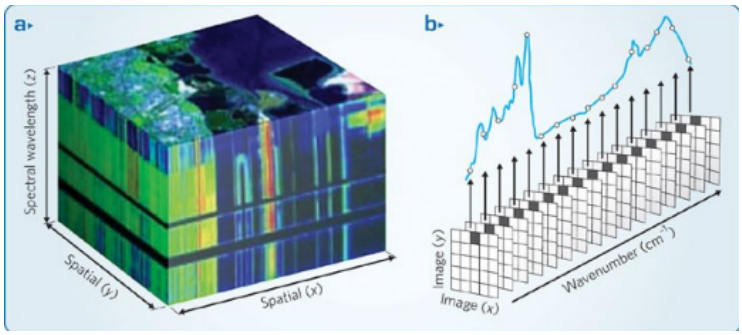

Figura 2.8: Ejemplo de representación de datos hiperespectrales. A la izquierda se observa la organización de la información en capas apiladas según la longitud de onda, mientras que a la derecha se muestra la respuesta espectral asociada a un punto de la imagen. Fuente: adaptado de Bannon (2009).

No obstante, el uso de imágenes hiperespectrales suele verse limitado por el volumen de datos generado, la elevada demanda computacional y la menor disponibilidad de misiones con alta cobertura espacial y temporal (Ma et al., 2015). Por este motivo, en el presente trabajo se prioriza el uso de imágenes multiespectrales, que ofrecen un compromiso adecuado entre información espectral, cobertura espacial y frecuencia de adquisición.

En este contexto, el sensor Multispectral Instrument (MSI) a bordo de la misión S2, desarrollada por la Agencia Espacial Europea (ESA) en el marco del programa Copernicus (COP), se posiciona como una de las principales fuentes de datos multiespectrales para estudios ambientales y agrícolas. El MSI combina una adecuada resolución espacial y espectral con una alta frecuencia de revisita y acceso libre a los datos, lo que ha impulsado su adopción en aplicaciones de monitoreo de la superficie terrestre a escala regional y global (Drusch et al., 2012a; Phiri et al., 2020).

2.4.1. Sentinel-2

La misión S2 constituye uno de los pilares actuales del SR óptico aplicado al monitoreo ambiental y agrícola. Está integrada al programa COP de la ESA y conformada por dos satélites gemelos, S2A y S2B, lanzados en 2015 y 2017, respectivamente. Ambos satélites poseen sensores y configuraciones técnicas idénticas y operan de manera coordinada sobre la misma órbita, con un desfase temporal entre sus pasadas. Esta disposición permite observar una misma región con mayor frecuencia, asegurando una cobertura global sistemática y continua, con una frecuencia de revisita cercana a los cinco días en latitudes medias, característica especialmente valiosa para el monitoreo de fenómenos dinámicos en la superficie terrestre (Drusch et al., 2012a).

El sensor Multispectral Instrument (MSI)(MSI) a bordo de S2 registra información en 13 bandas (véase Tabla 2.1), distribuidas a lo largo del espectro visible (Visible (VIS)), el infrarrojo cercano (NIR) y el infrarrojo de onda corta (SWIR). Estas bandas presentan resoluciones espaciales de 10, 20 y 60 metros, según la región espectral, lo que posibilita el análisis detallado de la vegetación, los cuerpos de agua, los suelos y las áreas urbanas a escalas compatibles con la gestión territorial y agrícola (Lillesand et al., 2015).

Banda	Descripción	Resolución (m)	λ_c (nm)	Ancho de banda (nm)
B1	Aerosol costero	60	443	20
B2	Azul	10	490	65
B3	Verde	10	560	35
B4	Rojo	10	665	30
B5	Red Edge	20	705	15
B6	Red Edge	20	740	15
B7	Red Edge	20	783	20
B8	NIR	10	842	115
B8A	Vegetation Red Edge	20	865	20
B9	Vapor de agua	60	945	20
B10	Cirros (SWIR)	60	1375	30
B11	SWIR	20	1610	90
B12	SWIR	20	2190	180

Tabla 2.1: Bandas y resoluciones del sensor MSI de la misión S2, incluyendo longitud de onda central y ancho de banda. Fuente: Phiri et al. (2020).

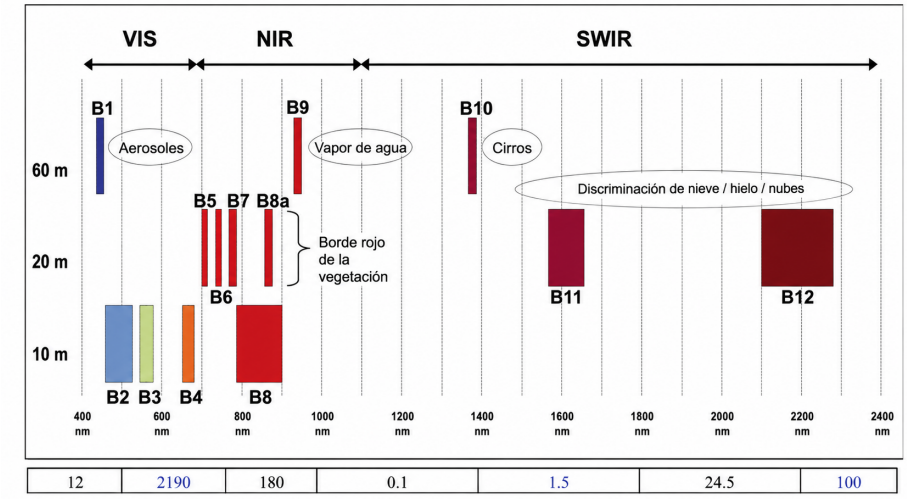

Figura 2.9: Distribución espectral y resolución espacial de las bandas del sensor MSI de S2. Cada rectángulo coloreado representa una de las 13 bandas espectrales del sensor, cuya posición indica el intervalo de longitudes de onda que abarca y cuya altura se relaciona con su resolución espacial. Adaptado de Drusch et al. (2012a) y (Cursos Teledetección, 2020).

La Figura 2.9 muestra la disposición espectral de las bandas del sensor MSI y la resolución espacial asociada a cada una. Tal como se indica en dicha figura 2.9, en el rango visible (VIS) las bandas Blue, Green y Red permiten caracterizar propiedades ópticas básicas de la superficie, como el color y la reflectancia general. En el infrarrojo cercano (NIR) y en la región del *Vegetation Red Edge* se concentra información clave para el análisis de la vegetación, particularmente relacionada con el vigor vegetal, la estructura foliar y la actividad fotosintéti-

ca; esta región incluye las bandas Vegetation Red Edge 1, 2 y 3. Por su parte, las bandas del infrarrojo de onda corta (SWIR), correspondientes a SWIR 1 y SWIR 2, resultan fundamentales para evaluar el contenido de humedad del suelo y de la vegetación, así como para la discriminación de superficies quemadas, nieve, hielo y nubes (Drusch et al., 2012a; Jensen, 2015).

Una de las principales ventajas de S2 radica en su aplicación en el ámbito agrícola. La combinación de sus bandas espectrales permite calcular numerosos índices de vegetación, entre ellos el Normalized Difference Vegetation Index (NDVI) (Índice de Vegetación de Diferencia Normalizada), ampliamente utilizado para estimar el vigor vegetal, detectar estrés hídrico y monitorear el desarrollo fenológico de los cultivos. Asimismo, la disponibilidad de bandas en el SWIR resulta clave para el análisis del contenido de humedad de la vegetación y del suelo, así como para la discriminación de distintos tipos de cobertura terrestre (Jensen, 2015).

Diversos estudios han demostrado que S2 tuvo un impacto significativo en el mapeo del uso y la cobertura del suelo, así como en el seguimiento de cultivos, bosques y recursos hídricos. En particular, trabajos de revisión destacan que esta misión representa una mejora sustancial respecto de satélites ópticos anteriores, tanto por la mayor cantidad de bandas espectrales disponibles como por su estabilidad radiométrica y su política de acceso libre a los datos (Phiri et al., 2020). Esta última ha favorecido su uso masivo en investigaciones académicas y aplicaciones institucionales y operativas, permitiendo la construcción de series temporales extensas, fundamentales para el análisis de cambios ambientales, la evolución de los sistemas productivos y los procesos de intensificación agrícola. En conjunto, estas características facilitan el desarrollo de metodologías consistentes, reproducibles y comparables a lo largo del tiempo (Drusch et al., 2012a; Jensen, 2015).

En el marco de este trabajo, las imágenes S2 resultan especialmente adecuadas para la detección de patrones espaciales característicos del paisaje agrícola, como los asociados a los sistemas de riego por pivote central SRPC. La combinación de una resolución espacial apropiada, una alta frecuencia de revisita y una información espectral rica permite no solo identificar estas estructuras, sino también analizar su evolución temporal y su relación con variables ambientales y productivas (Instituto Nacional de Tecnología Agropecuaria, 2011; Food and Agriculture Organization of the United Nations, 2021).

2.5. Gran volumen de datos

En el marco del SR, el concepto de *Big Data* refiere a conjuntos de datos de gran volumen, alta velocidad de generación y elevada diversidad, que exceden la capacidad de las herramientas tradicionales de almacenamiento y procesamiento (Ma et al., 2015). En el ámbito del SR, estas características se ven reforzadas por la complejidad espacial y temporal de la información (Zhu et al., 2017).

Este crecimiento se explica por la combinación de alta resolución espacial, información multiespectral por píxel —incluyendo bandas del visible, NIR y SWIR— y una elevada frecuencia de revisita, que permite construir series temporales densas, entendidas como aquellas con una alta frecuencia de observaciones en el tiempo (por ejemplo, intervalos de pocos días entre adquisiciones). Estas series resultan fundamentales para el estudio de procesos dinámicos, co-

mo la variabilidad estacional, los cambios en el uso del suelo o eventos extremos (Woodcock et al., 2008; Verbesselt et al., 2010).

Las misiones satelitales actuales, como S2, se inscriben plenamente en esta definición. Cada imagen multiespectral adquirida por el sensor MSI contiene información de 13 bandas espectrales y puede alcanzar tamaños de cientos de megabytes. Al analizar grandes áreas o series temporales prolongadas, el volumen de datos escala rápidamente a niveles de gigabytes o terabytes (Drusch et al., 2012a; Li et al., 2019).

En el ámbito agrícola, el análisis temporal de imágenes satelitales es clave para el monitoreo del crecimiento de cultivos y la detección de estrés hídrico (Atkinson and Tatnall, 1997). En particular, el estudio de sistemas de riego por pivote central SRPC requiere observar grandes extensiones de terreno de manera repetida, lo que incrementa la demanda computacional (Thenkabail et al., 2012).

El principal desafío asociado al Big Data en SR no es la disponibilidad de imágenes, sino la capacidad de procesarlas y extraer información útil de forma eficiente. Tareas como el cálculo de índices espectrales, por ejemplo el NDVI, o la detección de patrones espaciales, requieren flujos de trabajo automatizados y escalables, capaces de integrar grandes volúmenes de información espacial y temporal (Gorelick et al., 2017a; Ma et al., 2015).

En este contexto, plataformas de computación en la nube como *Google Earth Engine* se han convertido en herramientas fundamentales para el procesamiento de Big Data en SR. Google Earth Engine proporciona acceso directo a extensos catálogos de imágenes satelitales —incluyendo datos de S2— junto con una infraestructura de cómputo distribuido que permite realizar operaciones de filtrado, análisis espectral y procesamiento temporal sin necesidad de descargar los datos localmente (Gorelick et al., 2017a). Esta arquitectura resulta particularmente relevante en estudios agrícolas que requieren el análisis sistemático de series temporales extensas, como la identificación y el monitoreo de sistemas de riego por pivote central SRPC, donde la frecuencia de observación y la cobertura espacial generan volúmenes de datos difíciles de manejar mediante enfoques tradicionales (Thenkabail et al., 2012; Gorelick et al., 2017a).

2.6. Aprendizaje automático

Con el objetivo de reducir la carga de tareas repetitivas y mejorar la capacidad de análisis frente a problemas complejos, comenzaron a desarrollarse sistemas capaces de actuar y razonar de manera autónoma. Este proceso dio origen a la Inteligencia Artificial (IA), una disciplina que busca diseñar métodos para que las máquinas puedan tomar decisiones y resolver problemas sin intervención humana directa.

Dentro de este campo se encuentra el aprendizaje automático, cuyo propósito es construir modelos capaces de aprender a partir de datos. A diferencia de la programación tradicional, en la que el comportamiento del sistema se define mediante reglas explícitas, el aprendizaje automático permite que el modelo identifique patrones en los datos y mejore su desempeño a medida que incorpora nueva experiencia.

Una de las definiciones más influyentes de aprendizaje automático fue propuesta por Tom Mitchell en su obra *Machine Learning*. Según el autor, un pro-

grama aprende cuando su desempeño mejora como resultado de la experiencia adquirida:

> "Un programa de computadora aprende de una experiencia (**E**), respecto de una clase de tareas (**T**) y una medida de desempeño (**P**), si su desempeño en las tareas (**T**), medido mediante (**P**), mejora con la experiencia (**E**)" (Mitchell, 1997).

En esta formulación, **T** representa la tarea que el sistema debe realizar, como clasificar imágenes o predecir valores numéricos. La experiencia **E** corresponde a los datos utilizados para entrenar el modelo, mientras que **P** es la medida de desempeño que permite evaluar si el sistema mejora, por ejemplo mediante métricas como precisión, recuperación o error promedio. De este modo, un sistema puede considerarse capaz de aprender cuando su desempeño aumenta al ser expuesto a una mayor cantidad de datos relevantes.

Dentro del aprendizaje automático, es posible caracterizar este proceso en dos categorías principales: el aprendizaje supervisado, en el cual el modelo se entrena a partir de datos etiquetados que asocian entradas con salidas esperadas, y el aprendizaje no supervisado, donde el sistema identifica patrones o estructuras en los datos sin contar con etiquetas predefinidas.

Aprendizaje no supervisado

El aprendizaje no supervisado se utiliza cuando se trabaja con datos que no tienen etiquetas ni respuestas correctas asociadas. En este enfoque, el modelo no recibe indicaciones externas sobre qué representa cada dato, sino que analiza la información tal como se presenta y descubre por sí mismo cómo está organizada. El objetivo principal no es predecir un valor específico, sino identificar patrones, similitudes, agrupamientos o estructuras internas que permitan comprender mejor el conjunto de datos.

Aprendizaje supervisado

El aprendizaje supervisado es uno de los enfoques más utilizados dentro del aprendizaje automático. En este caso, el modelo se entrena a partir de ejemplos que cuentan con una respuesta correcta asociada, conocida como etiqueta. Cada dato de entrada está vinculado a una salida deseada, y el objetivo del sistema es aprender la relación entre ambas para luego poder generalizarla a datos nuevos.

Este enfoque suele ofrecer muy buenos resultados cuando se dispone de conjuntos de datos etiquetados de tamaño suficiente, lo que explica su uso extendido en aplicaciones como la clasificación de imágenes, la detección de fraude, la predicción de valores continuos y los sistemas de recomendación (Bishop, 2006). En el análisis de imágenes de SR, el aprendizaje supervisado resulta especialmente adecuado cuando se cuenta con ejemplos previamente identificados, como ocurre en tareas de detección o segmentación de estructuras agrícolas específicas, por ejemplo los sistemas de riego.

Dentro del aprendizaje supervisado existen distintos tipos de problemas, entre los que se destacan la regresión, orientada a la predicción de valores continuos, y la clasificación, cuyo objetivo es asignar cada instancia a una categoría discreta. En el contexto de este trabajo, la segmentación constituye un caso particular de clasificación a nivel de píxel, en el que se busca asignar una clase

a cada píxel de la imagen. Este tipo de aprendizaje supervisado es el de interés principal, ya que permite identificar y delimitar estructuras específicas en imágenes satélites.

2.7. Segmentación

La segmentación se inscribe dentro del campo de la Computer Vision (CV), disciplina que se ocupa de desarrollar métodos para que las computadoras puedan adquirir, procesar y analizar imágenes de manera automática. Dentro de este campo, las distintas tareas se diferencian principalmente por el nivel de detalle con el que describen el contenido visual de una escena, abarcando desde enfoques globales hasta representaciones espaciales finas de los objetos presentes (Goodfellow et al., 2016).

En este contexto, la segmentación constituye una de las tareas más avanzadas de la CV, ya que consiste en dividir una imagen, o cualquier conjunto de datos espaciales, en partes que tengan sentido desde el punto de vista del análisis. En lugar de tratar la imagen como un todo, la segmentación se enfoca en separarla en regiones más pequeñas y homogéneas, donde cada píxel o unidad queda asociado a una categoría específica. Este enfoque permite describir no solo qué objetos aparecen en la escena, sino también dónde se encuentran y cómo se organizan espacialmente.

Esta diferencia resulta clara al contrastar la segmentación con tareas más generales como la clasificación de imagenes, que se limita a asignar una etiqueta a la imagen completa (por ejemplo, “campo”, “ciudad” o “cultivo”), sin considerar la distribución interna de los objetos. Mientras la clasificación responde a la pregunta “¿qué hay en la imagen?”, la segmentación permite responder “¿qué hay, dónde está y cuál es su extensión?”, proporcionando una representación mucho más rica de la estructura interna de la imagen o del fenómeno observado (Goodfellow et al., 2016).

Dentro de este marco existen distintos tipos de segmentación, que se diferencian principalmente por el nivel de detalle que ofrecen. La **segmentación semántica** asigna una clase a cada píxel de la imagen según su categoría general, como suelo, agua, vegetación o edificaciones. De este modo, todas las áreas que pertenecen a una misma clase quedan agrupadas, lo que permite entender la composición general de la escena y la distribución espacial de cada tipo de cobertura. Sin embargo, este enfoque no distingue objetos individuales dentro de una misma clase: por ejemplo, varias parcelas cultivadas o varios animales aparecen como una sola región continua, sin separación entre individuos (Garcia-Garcia et al., 2018).

Por otro lado, la **segmentación de instancias** agrega un nivel de detalle adicional que resulta clave en muchas aplicaciones prácticas. En este caso, el modelo no solo clasifica cada píxel, sino que también identifica cada objeto de manera individual, incluso cuando varios pertenecen a la misma categoría. Además, delimita con precisión el contorno de cada objeto, marcando exactamente qué píxeles le corresponden. Esto permite diferenciar instancias concretas dentro de una misma clase, como distintos cultivos, estructuras agrícolas o elementos del paisaje. Gracias a esta capacidad, la segmentación de instancias se vuelve especialmente importante en contextos donde la forma, el tamaño y los límites precisos de los objetos son relevantes, como el monitoreo agrícola, la ins-

pección industrial, la conducción autónoma o el análisis detallado de imágenes satelitales (Minaee et al., 2021).

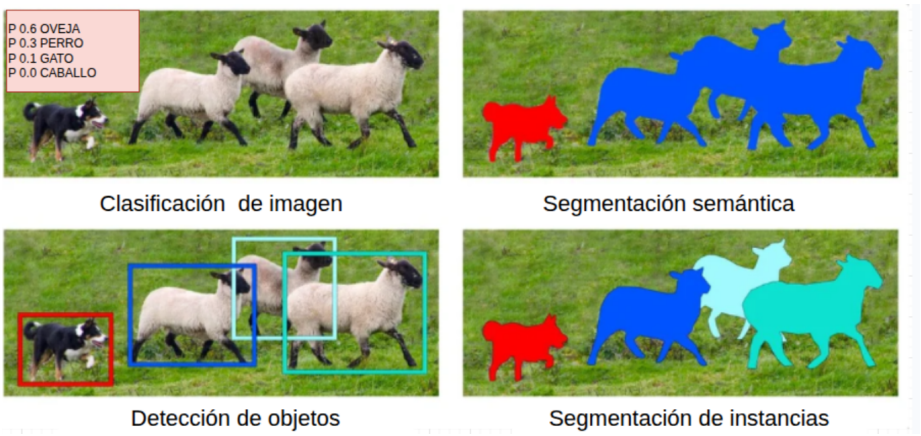

Figura 2.10: Comparación entre clasificación de imágenes, segmentación semántica, detección de objetos y segmentación de instancias. Adaptado de una imagen disponible en línea.

La Figura 2.10 muestra de manera clara cómo cambian los resultados según el tipo de enfoque utilizado para analizar una imagen. En el caso de la **clasificación de imágenes** (panel superior izquierdo), el modelo observa la imagen como un todo y responde únicamente a la pregunta "¿qué hay en esta imagen?". En la Figura 2.10, el sistema asigna probabilidades a distintas clases posibles (oveja, perro, gato, caballo), pero no tiene ninguna noción de cuántos objetos hay ni de dónde se encuentran dentro de la escena. Es decir, entiende el contenido general de la imagen, pero pierde completamente la información espacial (Krizhevsky et al., 2012).

En la **segmentación semántica** (panel superior derecho), el análisis es más detallado. El modelo ya no mira la imagen como un bloque único, sino que clasifica cada píxel según la categoría a la que pertenece. De esta forma, todas las ovejas aparecen coloreadas con el mismo color, el perro con otro, y el fondo con otro distinto. Esto permite comprender mucho mejor la estructura de la escena, ya que se sabe qué zonas corresponden a cada clase. Sin embargo, el modelo no distingue individuos: todas las ovejas son tratadas como un solo grupo, sin diferenciar cuántas hay ni cuáles son cuáles.

La **detección de objetos** (panel inferior izquierdo) da un paso más en esa dirección. En este enfoque, el modelo identifica cada objeto por separado y lo encierra dentro de una Bounding Box (BB). Así, no solo se sabe qué objetos hay, sino también cuántos son y dónde están ubicados dentro de la imagen. En la Figura 2.10 (panel inferior izquierdo), cada oveja y el perro aparecen marcados con un rectángulo independiente. No obstante, la información sobre la forma real del objeto sigue siendo aproximada, ya que la caja incluye también píxeles del fondo (Ren et al., 2015).

Finalmente, la **segmentación de instancias** combina lo mejor de todos los enfoques anteriores. El modelo no solo reconoce cada objeto individualmente, sino que además delimita con precisión su contorno, píxel por píxel. En la Figura 2.10 (panel inferior derecho), esto se observa claramente en cómo cada

oveja aparece segmentada de forma independiente, incluso cuando pertenecen a la misma clase, y con una silueta que se ajusta a su forma real. Este nivel de detalle permite saber qué objetos hay, cuántos son, dónde están y cuál es su geometría exacta, lo que resulta fundamental en aplicaciones donde la forma y los límites precisos son relevantes, como el sensado remoto y la agricultura de precisión (He et al., 2017).

De manera complementaria, la segmentación panóptica propone unificar la segmentación semántica y la segmentación de instancias en un único marco conceptual, asignando una clase a todos los píxeles de la imagen, tanto a los objetos individuales como a las regiones de fondo o contexto. Este enfoque permite obtener una descripción completa y coherente de la escena, integrando información global y local en una sola representación.

La Figura 2.10 representa una progresión en los enfoques de análisis de imágenes. Esta progresión puede leerse primero de izquierda a derecha en la fila superior (clasificación de imágenes → segmentación semántica) y luego continuar en la fila inferior (detección de objetos → segmentación de instancias). De este modo, se observa la transición desde métodos que solo responden "qué hay" en la imagen, hasta enfoques más avanzados que permiten comprender la escena en mayor detalle, identificando objetos individuales, su ubicación y su forma exacta.

Dentro de este marco, **You Only Look Once (YOLO)** es una familia de modelos de CV que, en sus versiones más recientes, no solo permite la detección de objetos, sino que también incorpora capacidades de segmentación. Su principal ventaja se basa en que analiza la imagen completa en una única pasada, lo que le permite operar en tiempo real con un alto nivel de eficiencia. De este modo, YOLO es capaz de identificar qué objetos hay en una imagen, dónde se encuentran y cuál es su forma exacta.

Con el paso del tiempo, YOLO ha ido evolucionando hacia arquitecturas cada vez más recientes que buscan mejorar el desempeño en tareas de detección y segmentación, al mismo tiempo que optimizan la velocidad de inferencia para su uso en escenarios prácticos. Las versiones orientadas a segmentación —como YOLOv8 Segmentation (YOLOv8-seg), YOLOv9 Segmentation (YOLOv9-seg) y la versión eficiente YOLO11s Segmentation (YOLO11s-seg)— incorporan una arquitectura base optimizada para la extracción de características, módulos que integran información a distintas escalas y una cabeza especializada en la generación de máscaras de segmentación de instancias. Gracias a este diseño, el modelo puede representar con gran detalle los objetos presentes en la escena, manteniendo un equilibrio entre calidad de las predicciones y eficiencia computacional.

En particular, YOLO11s-seg devuelve tres elementos para cada objeto que detecta. Primero, una **probabilidad de clase**, que indica la confianza del modelo de que el objeto detectado pertenezca a cada una de las clases consideradas, asignando finalmente aquella con mayor probabilidad. Segundo, una BB, que marca de forma aproximada la región de la imagen donde se encuentra el objeto. Y tercero, una **máscara de segmentación**, que identifica con precisión qué píxeles pertenecen al objeto detectado, permitiendo representar su forma real.

Esta combinación hace que YOLO11s-seg sea una herramienta potente para tareas de segmentación de instancias, ya que permite determinar simultáneamente qué objetos aparecen en la imagen, dónde están ubicados y cuál es su geometría. Esta capacidad resulta especialmente útil en escenarios complejos co-

mo el análisis de imágenes satelitales, la agricultura de precisión o la inspección automatizada.

Para evaluar su desempeño, los modelos de segmentación emplean distintas métricas que permiten medir tanto la capacidad de detección como la calidad de las máscaras generadas. Estas métricas comparan las predicciones del modelo con la referencia real, analizando aciertos, errores y niveles de confianza, entendidos como la probabilidad asociada a cada predicción que indica cuán seguro está el modelo de que un objeto detectado pertenezca a una determinada clase y localización. De este modo, es posible determinar si el modelo identifica correctamente los objetos, si los localiza con precisión y si las máscaras representan fielmente su forma. En la siguiente sección se describen estas métricas con mayor detalle.

2.8. Métricas

La calidad de un modelo de detección o segmentación —como los modelos de la familia YOLO— se evalúa mediante una serie de métricas que permiten medir de manera objetiva qué tan bien está haciendo su trabajo. Aunque de forma informal suele decirse que un modelo detecta bien o detecta mal, en la práctica es necesario analizar con detalle qué acierta y en qué se equivoca.

En este tipo de tareas, cada predicción que hace el modelo se puede comparar con la realidad y clasificar según si acertó o no. Estas posibles combinaciones entre lo que realmente hay en la imagen y lo que el modelo predice se organizan en lo que se conoce como la **matriz de confusión (CM)**. Esta matriz es una herramienta clave porque permite entender si el modelo tiende a inventar objetos, a perder detecciones o si mantiene un equilibrio razonable entre aciertos y errores.

2.8.1. Matriz de confusión

Estas categorías permiten entender si un modelo tiende a generar detecciones inexistentes, a perder objetos reales o si mantiene un equilibrio adecuado entre ambos tipos de error. En conjunto, conforman la CM, una herramienta que resume el comportamiento general del modelo a partir de la comparación entre las predicciones realizadas y los valores reales (Barrios, 2020).

La CM se compone de cuatro categorías básicas:

- **Verdadero positivo (VP):** el valor real es positivo y el modelo también predice positivo. Por ejemplo, una persona está enferma y la prueba lo detecta correctamente.
- **Verdadero negativo (VN):** el valor real es negativo y el modelo predice negativo. Por ejemplo, una persona no está enferma y la prueba lo confirma correctamente.
- **Falso positivo (FP):** el valor real es negativo, pero el modelo predice positivo. Por ejemplo, una persona no está enferma, pero la prueba indica erróneamente que sí lo está. Este caso corresponde a un error de tipo I.
- **Falso negativo (FN):** el valor real es positivo, pero el modelo predice negativo. Por ejemplo, una persona está enferma, pero la prueba indica

erróneamente que no lo está. En estadística, este caso corresponde a un error de tipo II y, en contextos como la salud, suele ser uno de los errores más críticos.

La Figura 2.11 muestra de manera esquemática cómo se relacionan los valores reales con las predicciones del modelo. En un eje se representa la condición real (positivo o negativo) y en el otro la condición predicha por el modelo. De esta forma, cada celda de la matriz indica un tipo de resultado posible: aciertos correctos (VP y VN) y errores (FP y FN). Esta representación permite visualizar rápidamente qué tipo de errores comete el modelo con mayor frecuencia y evaluar si su comportamiento está más orientado a perder detecciones reales o a generar detecciones incorrectas.

Figura 2.11: Matriz de confusión y relación entre valores reales y valores predichos. Adaptado de Barrios (2020).

A partir de los valores de la CM se definen métricas derivadas que permiten cuantificar distintos aspectos del desempeño del modelo. Entre las más utilizadas se encuentran la precisión Precision (PREC) y el recall Recall (REC).

PREC es una métrica que responde a la pregunta: *"De todas las veces que el modelo predijo un objeto positivo, ¿cuántas veces estuvo realmente acertado?"*. En otras palabras, la precisión indica qué proporción de las predicciones positivas realizadas por el modelo fue correcta. La precisión se calcula como:

$$\text{Precision} = \frac{VP}{VP + FP}$$

donde los VP se dividen por la suma de VP y FP; es decir, por todas las ocasiones en las que el modelo afirmó que había un objeto. Un modelo con alta precisión tiende a cometer pocos FP, lo que implica que cuando detecta un objeto, suele acertar.

REC, también denominado sensibilidad o tasa de VP, responde a la pregunta: *"De todos los objetos positivos que realmente existen, ¿cuántos logró detectar el modelo?"*. Esta métrica indica cuán exhaustivo es el modelo a la hora de encontrar todos los casos relevantes.

El recall se define como:

$$\text{Recall} = \frac{VP}{VP + FN}$$

donde los VP se dividen por la suma de VP y FN; es decir, por todas las instancias reales de la clase positiva. Un recall alto significa que el modelo pierde pocos FN, aunque en muchos casos esto puede implicar un aumento de FP.

La Figura 2.12 ilustra de forma geométrica la relación entre la precisión y el recall en función de los verdaderos positivos, falsos positivos y falsos negativos. Esta representación permite interpretar visualmente ambas métricas como proporciones de los elementos relevantes recuperados y de los elementos recuperados que resultan relevantes.

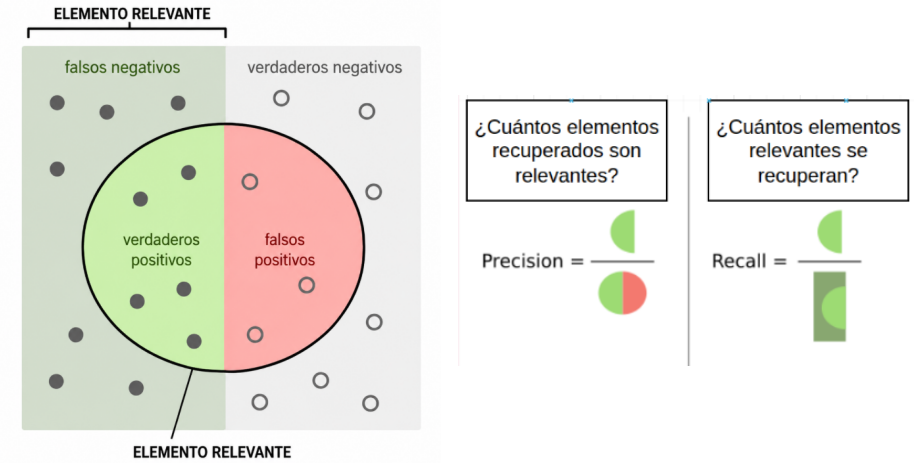

Figura 2.12: Representación geométrica de la relación entre precisión y recall. El rectángulo verde representa el conjunto de elementos realmente relevantes, mientras que el círculo representa los elementos recuperados por el modelo. La intersección entre ambos conjuntos corresponde a los verdaderos positivos; los elementos recuperados que no son relevantes corresponden a los falsos positivos; y los elementos relevantes que no fueron recuperados corresponden a los falsos negativos.

Dado que la PREC y el REC dependen del umbral de confianza del modelo, su relación se analiza mediante la **curva de Precisión–Recall**, que muestra el compromiso entre ambas métricas para distintos niveles de exigencia.

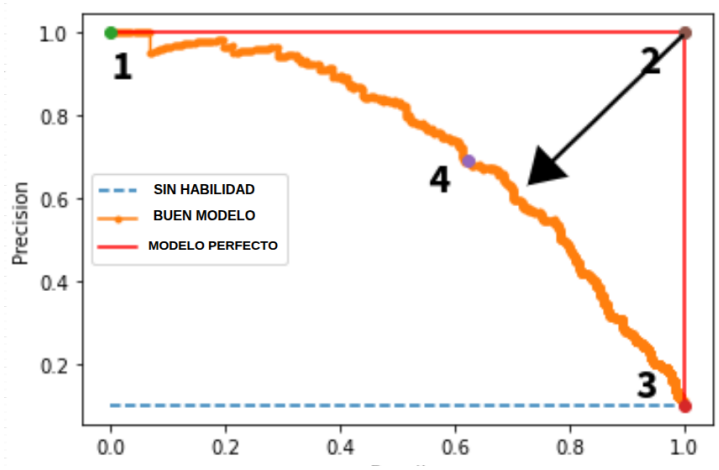

Figura 2.13: Ejemplo de curva Precisión–Recall (Precisión–Recall (PR)), donde se muestra la relación entre la PREC (eje vertical) y el REC (eje horizontal) para distintos umbrales de decisión. La curva azul representa el desempeño del modelo evaluado, mientras que la línea punteada corresponde a la referencia No Skill (No Skill) de un clasificador sin capacidad predictiva. Los puntos numerados indican distintos escenarios de funcionamiento: (1) alta precisión con bajo recall, (2) comportamiento ideal con precisión y recall máximos, (3) alto recall con pérdida de precisión y (4) un punto intermedio de compromiso entre ambas métricas.

En el **punto 1** de la Figura 2.13, ubicado en el extremo superior izquierdo de la curva PR, el REC es muy bajo y la PREC es casi perfecta. Este punto corresponde a un umbral de confianza muy alto, donde el modelo solo realiza predicciones cuando está extremadamente seguro. En este escenario hay pocos VP, muchos FN y casi ningún FP. Se trata de un modelo cauto: detecta pocos objetos, pero cuando detecta, suele acertar (Minaee et al., 2021).

El **punto 2** de la Figura 2.13, ubicado en el extremo superior derecho, representa el comportamiento de un modelo ideal, ilustrado por una línea horizontal con PREC igual a 1 y REC igual a 1. Un modelo perfecto sería capaz de detectar todos los objetos sin cometer errores, independientemente del umbral de confianza. Este caso es puramente teórico y se utiliza únicamente como referencia (Minaee et al., 2021).

En el **punto 3** de la Figura 2.13, ubicado en el extremo inferior derecho de la curva PR, el umbral de confianza es muy bajo. En este caso, el REC alcanza su valor máximo, ya que el modelo detecta todo lo que se parece mínimamente a un objeto. Sin embargo, al hacerlo introduce una gran cantidad de FP, provocando una caída significativa de la PREC. Aquí el modelo es arriesgado: encuentra muchos objetos, pero se equivoca con frecuencia (Minaee et al., 2021).

El **punto 4** de la Figura 2.13, ubicado en la zona media de la curva PR, representa un compromiso más equilibrado entre PREC y REC. Corresponde a un umbral intermedio en el que el modelo detecta una buena cantidad de objetos sin perder excesiva precisión. Este punto suele ser el más relevante en aplicaciones prácticas, ya que equilibra ambos objetivos (Minaee et al., 2021).

La figura incluye además una línea de referencia denominada *No Skill*, que representa el desempeño de un modelo sin capacidad predictiva, equivalente a

una predicción aleatoria. Una curva situada por encima de esta línea indica que el modelo aporta información útil. Un modelo robusto se caracteriza por mantener valores elevados de PREC incluso cuando REC comienza a aumentar; en cambio, una caída abrupta de PREC indica que el modelo se confunde rápidamente al intentar detectar más objetos (Minaee et al., 2021).

La curva PR resulta especialmente informativa en escenarios con **desbalance de clases**, ya que pone el foco en el desempeño del modelo sobre la clase positiva, que suele ser la de mayor interés en tareas de detección y segmentación. A diferencia de otras curvas de evaluación, la curva PR permite analizar con mayor detalle el compromiso entre PREC y REC cuando los casos positivos son minoritarios. No obstante, en contextos con fuerte desbalance, la curva puede no ser convexa; esto implica que distintos tramos representan compromisos diferentes entre ambas métricas y que pequeñas variaciones en el umbral de decisión pueden generar cambios abruptos en el comportamiento del modelo. Por este motivo, el **área bajo la curva** debe interpretarse principalmente con fines comparativos, permitiendo analizar cómo varía el equilibrio entre PREC y REC a lo largo de distintos umbrales de decisión (Minaee et al., 2021).

2.8.2. (Intersection over Union (IoU))

En detección y segmentación no es suficiente con saber si el modelo detectó un objeto, sino que resulta necesario evaluar qué tan bien lo ubicó y qué tan precisa es la forma predicha respecto de la forma real. Para ello se utiliza una métrica central denominada **Intersection over Union** (**IoU**). El IoU compara dos regiones: la región real del objeto y la región predicha por el modelo, las cuales pueden representarse mediante una BB o mediante una máscara. Una BB corresponde a una caja rectangular que envuelve al objeto y permite localizarlo dentro de una imagen, aunque no reproduce con precisión su forma cuando esta es curva o irregular. Por otro lado, las **máscaras** son representaciones binarias, compuestas por ceros y unos, donde cada píxel indica si pertenece o no al objeto, permitiendo describir con mayor detalle su silueta, bordes y contorno.

Para que una predicción sea considerada un VP, el valor de IoU entre la región predicha y la región real debe superar un **umbral predefinido**. Este umbral establece el grado mínimo de superposición aceptable para considerar que el objeto fue correctamente detectado y localizado. En la práctica, uno de los criterios más utilizados establece un umbral de IoU ≥ 0.5, introducido en desafíos de referencia como PASCAL VOC para la evaluación de algoritmos de detección de objetos (Everingham, 2010). En evaluaciones más exigentes pueden emplearse umbrales superiores, como 0.75 o mayores. Si el valor de IoU no alcanza el umbral establecido, la predicción se considera un FP, aun cuando el modelo haya identificado correctamente la clase del objeto.

Como se observa en la Figura 2.14, el concepto de IoU se ilustra mediante dos regiones superpuestas: una corresponde al objeto real y la otra a la predicción del modelo. El área donde ambas regiones coinciden se denomina **intersección**, mientras que la superficie total cubierta por ambas regiones se denomina **unión**. El IoU se define como el cociente entre el área de intersección y el área de unión:

$$IoU = \frac{\text{Área de intersección}}{\text{Área de unión}}$$

Cuando la predicción coincide casi perfectamente con el objeto real, el área de intersección es grande y el valor de IoU se aproxima a 1. En cambio, si la superposición es mínima, el IoU toma valores cercanos a 0. Esta métrica resulta clave porque permite cuantificar de manera precisa qué tan bien coinciden las formas predichas con las reales, diferenciando entre detecciones aproximadas y localizaciones verdaderamente precisas (SuperAnnotate, 2021).

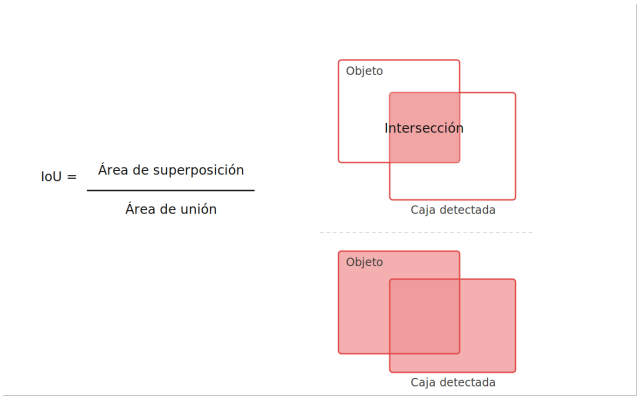

Figura 2.14: Esquema del cálculo de Intersección sobre Unión (IoU) entre la región real del objeto y la región predicha por el modelo.

Valores de IoU cercanos a 1 indican una coincidencia casi perfecta entre la región predicha y la región real, mientras que valores cercanos a 0 reflejan una superposición mínima. Además de su interpretación geométrica, el IoU se utiliza como criterio de decisión para clasificar las predicciones del modelo: una detección se considera VP únicamente cuando su IoU supera un umbral predefinido; en caso contrario, se considera FP. Este criterio resulta fundamental para el cálculo de métricas de evaluación como PREC, REC y *average precision* (precisión promedio), ya que establece un estándar mínimo de solapamiento para considerar correcta una detección (SuperAnnotate, 2021).

Capítulo 3

Procesamiento De Datos

3.1. Bandas Espectrales de Sentinel-2

En primer lugar, definimos las combinaciones de bandas espectrales de Sentinel-2 (S2) que consideramos más adecuadas para resaltar áreas irrigadas por Sistema de riego de pivote central (SRPC) en imágenes satelitales. Para ello, trabajamos con imágenes obtenidas y preprocesadas mediante Google Earth Engine (GEE), lo que nos permitió acceder al catálogo de S2, filtrar los datos por período y nubosidad, aplicar máscaras de nubes y generar composiciones temporales consistentes (Drusch et al., 2012a; Gorelick et al., 2017b).

Definimos el período de análisis para la estación primavera–verano en la provincia de Córdoba, cuando se concentró la mayor actividad fotosintética de los cultivos extensivos y, en consecuencia, se intensificaron los contrastes espectrales entre parcelas irrigadas y no irrigadas. En particular, trabajamos con composiciones generadas entre el **1 de agosto de 2023 y el 31 de marzo de 2024**, ventana temporal que abarcó desde la implantación del cultivo, es decir, desde las etapas iniciales posteriores a la siembra y emergencia de las plantas, hasta etapas avanzadas del ciclo de cultivos como soja y maíz. En ambos casos, el riego suplementario se asoció a fases de alta demanda hídrica y se manifestó en incrementos del vigor vegetativo y en la atenuación de señales de estrés respecto del entorno no irrigado, lo que volvió especialmente adecuada esta ventana temporal para su detección mediante información espectral (TRAXCO, 2013; Climate FieldView Argentina, 2022).

Durante el desarrollo del trabajo, evaluamos distintas combinaciones multiespectrales en pseudocolor, cada una seleccionada para destacar contrastes específicos entre superficies irrigadas y su entorno agrícola, aprovechando la riqueza espectral del sensor (Drusch et al., 2012a). A continuación, se describen las combinaciones utilizadas a lo largo de este trabajo.

Color natural (B4, B3, B2). Utilizamos la composición en color natural, formada por las bandas B4 (rojo, 665 nm), B3 (verde, 560 nm) y B2 (azul, 490 nm), asignadas respectivamente a los canales rojo, verde y azul (RGB), como referencia inicial para la interpretación visual de la escena. Esta combinación reproduce aproximadamente la percepción visual humana, en la que la vegetación activa se observa en tonos verdes, mientras que los suelos desnudos y las

superficies no vegetadas aparecen en tonalidades grises o marrones (GIS Geography, 2020). Esta representación facilitó una identificación visual preliminar de patrones circulares asociados a SRPC, como se observa en la Figura 3.1.

Figura 3.1: Imagen S2 en color natural (B4, B3, B2) correspondiente a la provincia de Córdoba. Los contornos negros son anotaciones superpuestas que delimitan parcelas circulares identificadas como áreas bajo riego por pivote central. Imagen generada a partir de datos Sentinel-2 procesados en Google Earth Engine.

Bordes rojos (B7, B6, B5). Evaluamos la combinación de bandas del *bordes rojos*, asignando B7 (783 nm) al canal rojo, B6 (740 nm) al canal verde y B5 (705 nm) al canal azul, como se observa en la Figura 3.2. Esta composición fue seleccionada por su sensibilidad a variaciones en la estructura y el estado fisiológico de la vegetación. Si bien estas bandas presentan una resolución espacial de 20 m, como se indicó en la Tabla 2.1, consideramos que aportan información relevante sobre el vigor del cultivo y la densidad del follaje, lo que permitió resaltar diferencias entre áreas irrigadas y no irrigadas y delinear con mayor claridad los límites circulares característicos de los pivotes (Sentinel Hub, 2021a; Drusch et al., 2012a).

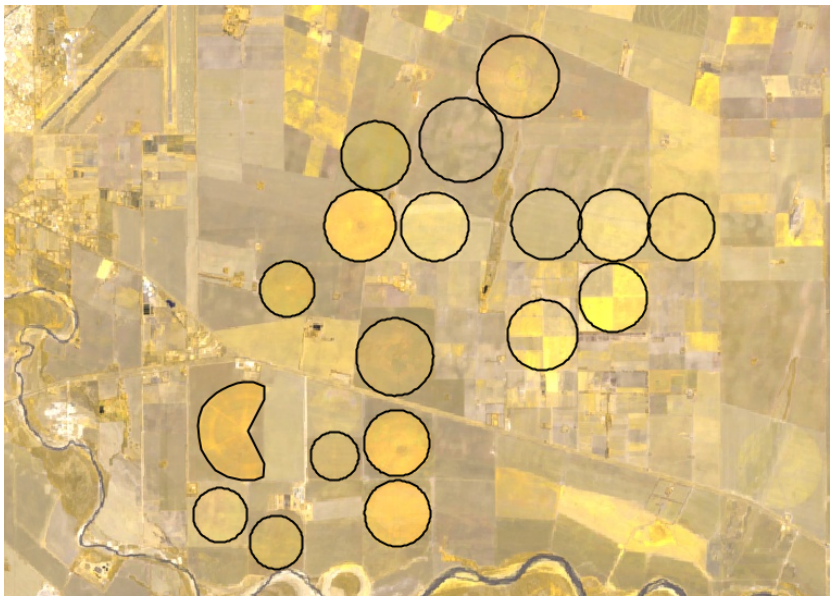

Figura 3.2: Imagen S2 utilizando la combinación de bordes rojos (B7, B6, B5) correspondiente a la provincia de Córdoba. Los contornos negros son anotaciones superpuestas que delimitan parcelas circulares identificadas como áreas bajo riego por pivote central. Imagen generada a partir de datos Sentinel-2 procesados en Google Earth Engine.

Falso color SWIR (B11, B8, B4). Como se observa en la Figura 3.3, seleccionamos la composición de falso color SWIR, asignando B11 (Shortwave Infrared (SWIR), 1610 nm) al canal rojo, B8 (Near Infrared (NIR), 842 nm) al canal verde y B4 (rojo visible, 665 nm) al canal azul. Esta combinación fue elegida por su capacidad para destacar simultáneamente biomasa vegetal y contenido hídrico del suelo. En esta representación, las zonas con mayor disponibilidad de agua tienden a manifestarse con tonalidades más intensas, lo que resultó particularmente útil para diferenciar áreas de riego activo de otros patrones circulares no asociados a humedad persistente (GIS Geography, 2020; Sentinel Hub, 2021b).

Figura 3.3: Imagen S2 en falso color SWIR (B11, B8, B4) correspondiente a la provincia de Córdoba. Los contornos negros son anotaciones superpuestas que delimitan parcelas circulares identificadas como áreas bajo riego por pivote central. Imagen generada a partir de datos Sentinel-2 procesados en Google Earth Engine.

Falso color infrarrojo (B8A, B4, B3). Finalmente, empleamos la combinación de falso color infrarrojo asignando B8A (NIR estrecho, 865 nm) al canal rojo, B4 (rojo visible, 665 nm) al canal verde y B3 (verde visible, 560 nm) al canal azul. Esta variante de la composición infrarroja clásica reduce la saturación en zonas de vegetación densa. En esta representación, la vegetación saludable se visualiza en tonos rojos intensos, lo que permitió resaltar con claridad la geometría circular de las parcelas irrigadas y apoyar el análisis del vigor vegetativo, como se observa en la Figura 3.4 (GIS Geography, 2020).

Figura 3.4: Imagen S2 en falso color infrarrojo (B8A, B4, B3) correspondiente a la provincia de Córdoba. Los contornos negros son anotaciones superpuestas que delimitan parcelas circulares identificadas como áreas bajo riego por pivote central. Imagen generada a partir de datos Sentinel-2 procesados en Google Earth Engine.

En conjunto, utilizamos estas combinaciones multiespectrales para resaltar propiedades biofísicas complementarias: color natural para contexto visual, *bordes rojos* para la condición del cultivo, SWIR para humedad y falso color infrarrojo para enfatizar vegetación activa. Estas visualizaciones, generadas como composiciones temporales en GEE y exportadas como archivos Geographic Tagged Image File Format (GeoTIFF) georreferenciados (Open Geospatial Consortium (OGC), 2019), constituyeron la base de entrada para la detección automática de patrones circulares de riego mediante el modelo *Grounding DINO*, así como para su posterior integración en entornos de Sistemas de Información Geográfica (SIG), entendidos como plataformas de software para la visualización, gestión y análisis de información espacial georreferenciada (QGIS Project, 2026).

3.2. Grounding DINO

Con el objetivo de automatizar la detección de áreas circulares irrigadas, se empleó el modelo de detección de objetos (object detection) *Grounding DINO* (Liu et al., 2023) para generar las etiquetas necesarias para el entrenamiento del modelo YOLO. Este modelo se enmarca dentro del enfoque de *open-set* (conjunto abierto) u *open-vocabulary object detection* (detección de objetos con vocabulario abierto), lo que implica que puede identificar objetos a partir de descripciones en lenguaje natural, incluso cuando dichos objetos no forman parte de un conjunto cerrado de clases utilizado durante su entrenamiento (Liu et al., 2023). Esta característica resulta particularmente útil en el contexto de

imágenes satelitales, donde objetos de interés como los pivotes de riego no suelen estar representados explícitamente en conjuntos de datos genéricos de Computer Vision (CV).

Elegimos las consultas textuales de forma amplia y sencilla, apuntando únicamente a que el modelo reconozca formas circulares en imágenes satelitales, sin entrar en descripciones específicas. Se usaron expresiones genéricas como *"satellite view circle"*, *"satellite crop circle"* y *"circle"*, como se muestra en el Código 3.2.1, justamente para no limitar al modelo y dejarlo trabajar con mayor libertad a la hora de identificar estos patrones (Liu et al., 2023).

Con el fin de reducir la aparición de detecciones erróneas y priorizar regiones con mayor probabilidad de corresponder a pivotes de riego, se aplicaron umbrales mínimos tanto sobre la confianza de las Bounding Box (BB) generadas por el modelo como sobre la similitud texto–imagen asociada a cada consulta. En este trabajo se adoptó un valor de **0.30** como umbral para la confianza de las detecciones (*box threshold*) y un valor de **0.30** para la similitud vinculada a la consulta textual (*text threshold*). Estos valores fueron seleccionados de manera empírica durante la etapa de inferencia exploratoria, buscando conservar suficientes detecciones candidatas para no descartar posibles pivotes en una fase temprana del proceso. Posteriormente, las detecciones obtenidas fueron refinadas mediante segmentación y control geoespacial. Estos parámetros, junto con el umbral de supresión de no-máximos (*NMS IoU*), se resumen en el Código 3.2.1, que refleja la configuración utilizada durante la etapa de inferencia. Este criterio permitió establecer un compromiso entre sensibilidad y precisión, favoreciendo la inclusión de detecciones potencialmente relevantes en una primera etapa (Liu et al., 2023).

Código 3.2.1 Parámetros y consultas textuales utilizados en Grounding DINO

```
TEXT_PROMPT = [
    "satellite view circle",
    "satellite crop circle",
    "satellite view crop circle",
    "circle"
]

BOX_THRESHOLD  = 0.30  # confianza mínima
TEXT_THRESHOLD = 0.30  # similitud mínima
NMS_IOU        = 0.40  # umbral IoU para NMS
```

Como salida, Grounding DINO generó un conjunto de BB que indican la localización aproximada de las regiones detectadas, junto con un valor de confianza asociado a cada detección. El resultado de este proceso se ilustra en la Figura 3.5, donde se muestran las detecciones superpuestas sobre un parche de imagen S2 en composición falso color. Asimismo, el proceso de inferencia produjo imágenes ráster de salida en formato convencional (`.png`), es decir, representaciones digitales compuestas por una matriz de píxeles donde cada celda almacena información visual de la imagen, utilizadas inicialmente para la inspección visual de las detecciones (Liu et al., 2023). Si bien estas imágenes resultan adecuadas para este fin, no contienen información de georreferenciación ni preservan explícitamente la grilla espacial del parche S2 original.

Con el objetivo de garantizar la coherencia espacial necesaria para el análisis geoespacial posterior, las salidas ráster generadas en formato `.png` fueron convertidas a formato GeoTIFF `.tif`, incorporando la información de referencia espacial correspondiente al parche original, tales como: extensión, resolución, origen y sistema de coordenadas (Open Geospatial Consortium (OGC), 2019; GDAL/OSGeo, 2025a). Esta conversión permitió alinear correctamente las detecciones con las imágenes S2 originales y posibilitó su integración directa en entornos de SIG (QGIS Project, 2026).

Dado que Grounding DINO proporciona únicamente una localización aproximada mediante BBs, el modelo se integró con el Segment Anything Model (SAM)(Modelo de Segmentación de Cualquier Objeto) utilizando la variante **ViT-H**. Esta variante corresponde a una arquitectura basada en *Vision Transformer* de gran tamaño, donde la letra H hace referencia a *Huge*, es decir, una versión de mayor capacidad dentro de la familia de modelos disponibles. Para este trabajo se utilizaron pesos preentrenados (`sam_vit_h_4b8939.pth`) (Kirillov et al., 2023). En este esquema, cada BB se utilizó como *prompt* espacial para SAM, que generó una **máscara** binaria delineando el objeto completo contenido dentro de la caja. El resultado de esta integración se presenta en la Figura 3.6, donde se observa una máscara binaria representativa obtenida a partir de una detección inicial. Esta integración permitió transformar detecciones aproximadas en objetos con contornos ajustados, reduciendo significativamente el esfuerzo de anotación manual.

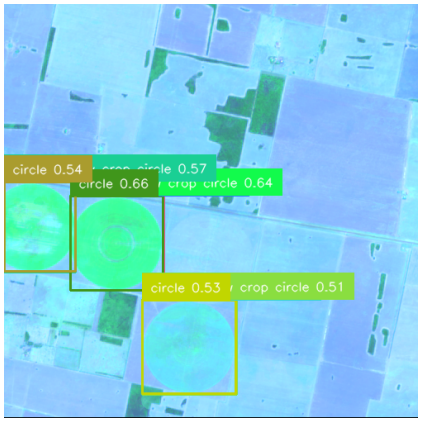

Figura 3.5: Detección automática de pivotes de riego mediante Grounding DINO sobre una imagen S2 en composición falso color. Los recuadros de colores corresponden a las BB generadas por el modelo para delimitar posibles áreas irrigadas por pivote central. Las etiquetas indican la clase predicha y el valor de confianza asociado a cada detección.

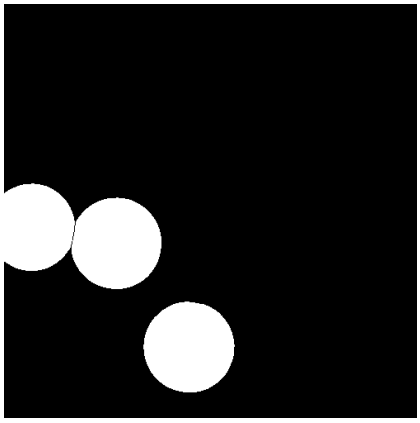

Figura 3.6: Máscara binaria de pivotes obtenida mediante la integración Grounding DINO–SAM. Los píxeles blancos representan las regiones identificadas como áreas pertenecientes a pivotes de riego, mientras que los píxeles negros corresponden al fondo o zonas no detectadas.

Las máscaras resultantes, ya alineadas espacialmente con los parches originales, constituyeron el insumo directo para su posterior vectorización y organi-

zación geoespacial en Quantum Geographic Information System (QGIS). (QGIS Project, 2026).

3.3. Uso de QGIS para el análisis y organización de la información espacial

QGIS es un software de SIG de código abierto, ampliamente utilizado para la visualización, edición, análisis y gestión de datos geoespaciales (QGIS Project, 2026). Permite trabajar de manera integrada con información raster (imágenes satelitales, índices espectrales y máscaras) y vectorial (puntos, líneas y polígonos), ofreciendo un entorno gráfico que facilita la inspección y la organización de resultados espaciales complejos.

En este trabajo, QGIS se utilizó como entorno principal para integrar y organizar las salidas obtenidas en la detección automática de pivotes (Sección 3.2). Mientras que la etapa previa produjo máscaras raster a partir de modelos de CV ejecutados en notebooks de Google Colab, QGIS permitió ordenar dichas salidas dentro de un marco geográfico coherente, controlar la georreferenciación, mantener la trazabilidad por parche y preparar un insumo vectorial consistente para su uso posterior en entornos de análisis y entrenamiento supervisado.

Las máscaras binarias generadas por la integración Grounding DINO–SAM se almacenaron como rasters georreferenciados y se cargaron junto con los parches S2 originales en un mismo proyecto QGIS. Esta integración permitió verificar la correspondencia espacial entre cada máscara y su parche de origen, asegurando que ambos compartieran la misma extensión, resolución, origen y sistema de referencia de coordenadas. De este modo, se garantizó una alineación píxel a píxel entre máscara y parche, condición necesaria para la correcta interpretación espacial de las detecciones y para las etapas posteriores de vectorización y generación de anotaciones.

A partir de estas máscaras raster, se llevó a cabo la vectorización mediante la herramienta *GDAL Polygonize*, provista por la biblioteca Geospatial Data Abstraction Library (GDAL) e integrada en QGIS como *"Raster a polígono"* (GDAL/OSGeo, 2025b). Este procedimiento identifica regiones contiguas con valor binario uno (1) dentro de la máscara y genera polígonos cerrados que siguen el contorno del objeto segmentado, preservando la referencia espacial del raster de entrada. Como resultado, cada pivote detectado quedó representado como una geometría vectorial explícita, adecuada para su inspección cartográfica y para su posterior utilización como etiqueta geoespacial.

Dado que el procesamiento de detección se realizó por parches independientes, el resultado inicial consistió en múltiples capas vectoriales individuales cargadas de forma simultánea en el proyecto. Para facilitar la inspección global y el control de consistencia entre resultados parciales, se organizó una visualización denominada capa combinada, utilizada para contrastar detecciones provenientes de distintos parches o configuraciones.

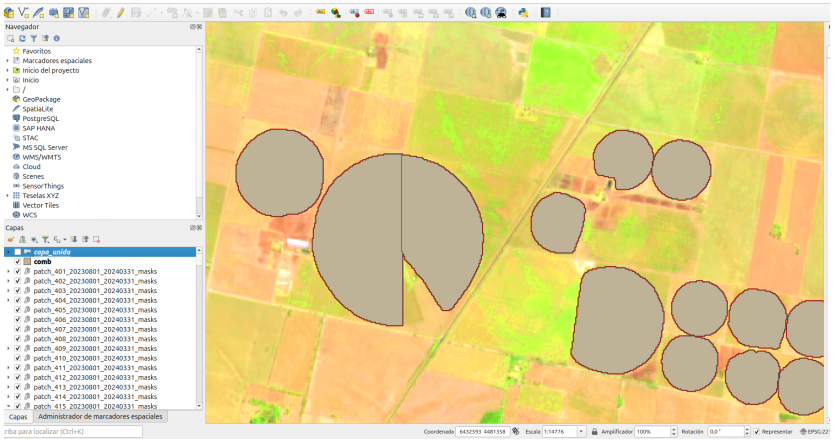

Figura 3.7: Visualización en QGIS de la capa combinada, utilizada para contrastar resultados parciales provenientes de distintos parches o configuraciones. Las regiones en gris corresponden a las máscaras generadas para las áreas identificadas como pivotes de riego.

Tras el control visual y la verificación de coherencia espacial, todas las geometrías válidas se consolidaron en un único archivo vectorial maestro, denominado "capa unida", que integra la totalidad de las detecciones en un solo producto geoespacial.

Figura 3.8: Visualización en QGIS de la capa unida, correspondiente al producto vectorial maestro que consolida las detecciones de pivotes de riego. Las regiones verdes representan detecciones provenientes de una capa de entrada, mientras que las regiones rojas corresponden a detecciones incorporadas desde otras capas durante el proceso de combinación.

Dicha capa se almacenó en formato GeoPackage (GPKG) (`.gpkg`), seleccionado por su robustez y por su capacidad para integrar geometrías y atributos en un único contenedor interoperable (Open Geospatial Consortium (OGC), 2022). Cada geometría se asocia a un conjunto mínimo de campos orientados a garantizar identificación, trazabilidad y reutilización posterior de los datos.

En particular, el campo `fid` actúa como identificador interno de la geometría; `DN` corresponde al valor digital heredado de la máscara raster utilizada durante la vectorización; `patch` indica el parche satelital de origen; `layer` referencia la máscara raster desde la cual se derivó la detección; `path` almacena la ruta al archivo de origen; y `id` corresponde a un identificador único asignado a cada pivote, utilizado para su seguimiento y para la generación posterior de anotaciones y particiones del dataset. La estructura de esta tabla de atributos se presenta en la Figura 3.9.

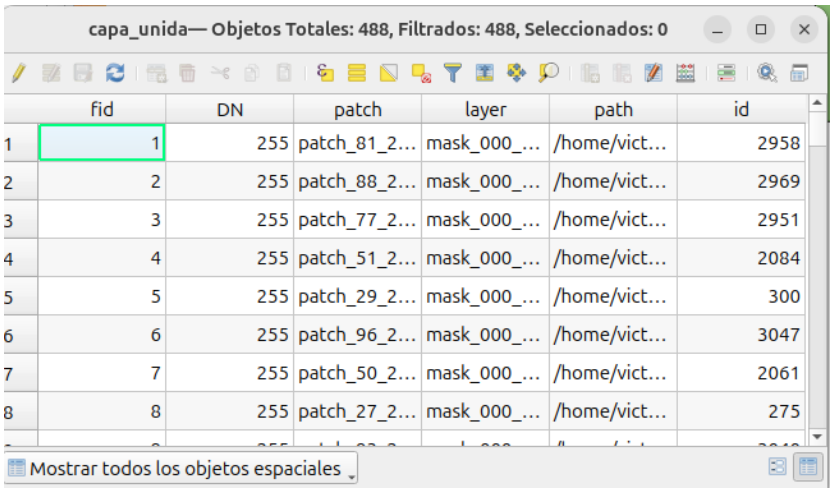

	fid	DN	patch	layer	path	id
1	1	255	patch_81_2...	mask_000_...	/home/vict...	2958
2	2	255	patch_88_2...	mask_000_...	/home/vict...	2969
3	3	255	patch_77_2...	mask_000_...	/home/vict...	2951
4	4	255	patch_51_2...	mask_000_...	/home/vict...	2084
5	5	255	patch_29_2...	mask_000_...	/home/vict...	300
6	6	255	patch_96_2...	mask_000_...	/home/vict...	3047
7	7	255	patch_50_2...	mask_000_...	/home/vict...	2061
8	8	255	patch_27_2...	mask_000_...	/home/vict...	275

Figura 3.9: Tabla de atributos de la *capa unida*, donde se observan los campos de identificación y trazabilidad asociados a cada detección.

Durante todo el flujo se mantuvo especial cuidado en preservar la coherencia de la referencia espacial. Las composiciones S2 exportadas desde GEE conservaron su sistema de coordenadas original (Gorelick et al., 2017b), el cual fue heredado por las máscaras raster y posteriormente por las geometrías vectoriales resultantes. Para garantizar consistencia en los cálculos métricos y evitar desfasajes derivados de reproyecciones implícitas, la capa unida se estandarizó finalmente al sistema de referencia proyectado **EPSG:22174 (POSGAR 98)** (EPSG Geodetic Parameter Dataset, 2024), que constituye el estándar oficial adoptado por la Infraestructura de Datos Espaciales de la Provincia de Córdoba.

Como resultado de esta etapa se obtuvo un archivo vectorial que reúne los pivotes de riego detectados como geometrías georreferenciadas, directamente derivadas de las máscaras segmentadas y alineadas con los parches satelitales de origen. Esta organización permitió mantener una correspondencia clara entre cada pivote y la imagen en la que fue identificado.

Si bien modelos como Grounding DINO (Liu et al., 2023) y SAM (Kirillov et al., 2023) permiten obtener detecciones y segmentaciones precisas sin entrenamiento supervisado específico, su utilización se limitó en este trabajo a la etapa de generación automática de anotaciones. La decisión de trasladar dichas anotaciones al formato You Only Look Once (YOLO) y entrenar un modelo dedicado responde a criterios de eficiencia computacional, reproducibilidad y escalabilidad. En particular, un modelo YOLO entrenado específicamente para la detección de pivotes de riego permite realizar inferencias rápidas y consisten-

tes sobre grandes volúmenes de imágenes, sin depender de prompts en lenguaje natural ni de la ejecución conjunta de múltiples modelos.

De este modo, las salidas de Grounding DINO y SAM se emplearon como pseudo-etiquetas, es decir, anotaciones generadas automáticamente por un modelo previamente entrenado en lugar de ser creadas manualmente por un usuario. Estas pseudo-etiquetas permitieron construir un conjunto de datos supervisado, dejando el dataset preparado para su uso posterior en la definición de los conjuntos de entrenamiento y validación y en la evaluación sistemática del desempeño del modelo final.

3.4. Generación de anotaciones YOLO

Con la información espacial ya integrada en la capa unida, se procedió a transformar las geometrías vectoriales georreferenciadas en anotaciones compatibles con modelos de detección y segmentación basados en la arquitectura YOLO. Esta etapa se realizó mediante scripts desarrollados en Python, que permitieron automatizar la conversión desde representaciones SIG a archivos de texto plano (`.txt`) en el formato requerido por el modelo (Ultralytics, 2026; Roboflow / Community reference, 2024).

El procedimiento se basó en articular dos tipos de insumos: por un lado, los parches de imagen en formato GeoTIFF, que definen la extensión espacial y la grilla de referencia; y por otro, la capa vectorial maestra que contiene los polígonos correspondientes a los pivotes de riego detectados. Ambos insumos comparten el mismo sistema de referencia espacial, condición necesaria para garantizar una correspondencia geométrica correcta entre imágenes y anotaciones.

Para cada imagen GeoTIFF, el script calcula en primer lugar su geometría envolvente (*bounding box* espacial), que representa el área cubierta por el parche. Esta geometría se utiliza para identificar qué polígonos de la *capa unida* intersectan efectivamente la imagen, descartando aquellos objetos que quedan fuera de su extensión espacial (Open Geospatial Consortium (OGC), 2019, 2022).

Una vez identificadas las intersecciones válidas, las geometrías vectoriales se recortan a la extensión del parche y se filtran según un umbral mínimo de área, con el objetivo de eliminar detecciones marginales o fragmentos demasiado pequeños para ser considerados objetos relevantes. Este criterio permitió reducir el ruido en las anotaciones finales y mejorar la calidad del conjunto de entrenamiento (Ultralytics, 2026).

A partir de las geometrías resultantes, se generan los archivos de anotación en formato YOLO (Ultralytics, 2026; Roboflow / Community reference, 2024). Para cada imagen se crea un archivo `.txt` con el mismo nombre base, asegurando una correspondencia uno a uno entre imagen y etiqueta. Cada línea del archivo representa un objeto detectado e incluye el identificador de clase seguido de las coordenadas normalizadas que describen el contorno del objeto, de acuerdo con el formato utilizado por YOLO para tareas de segmentación (Roboflow / Community reference, 2024).

Las coordenadas de los vértices se expresan en el sistema de referencia de la imagen, normalizadas en el rango $[0, 1]$ respecto del ancho y alto del parche. Este proceso implica transformar coordenadas geográficas a coordenadas relativas a la imagen, garantizando compatibilidad directa con el formato de entrada

esperado por YOLO para modelos de segmentación supervisada (Ultralytics, 2026; Roboflow / Community reference, 2024).

Un ejemplo del resultado de este proceso puede observarse en la Figura 3.10, donde se ilustran las anotaciones generadas en formato YOLO para un parche satelital, representadas como contornos poligonales normalizados correspondientes a los pivotes de riego detectados. Este ejemplo visual permite verificar la correcta correspondencia geométrica entre las geometrías vectoriales originales y su codificación final en el formato de anotación utilizado para el entrenamiento del modelo.

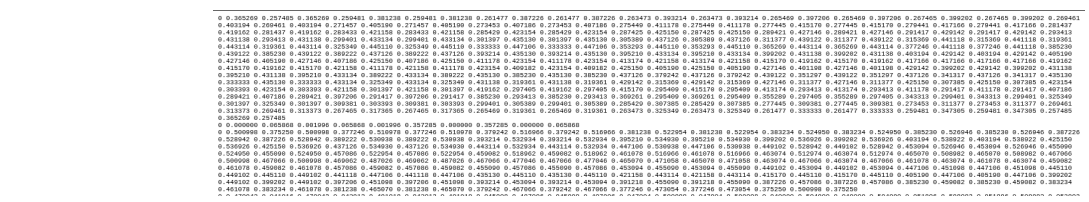

Figura 3.10: Ejemplo de anotaciones en formato YOLO generadas a partir de las geometrías vectoriales de pivotes de riego. Cada objeto se representa mediante un conjunto de coordenadas normalizadas que describen el contorno del pivote dentro del parche satelital correspondiente.

El flujo completo de generación de anotaciones se ejecutó de forma automática sobre el conjunto de imágenes, permitiendo producir de manera reproducible y sistemática los archivos `.txt` correspondientes a cada parche. De este modo, se preservó la trazabilidad entre imagen satelital, geometría vectorial y anotación final, asegurando coherencia espacial y consistencia entre datos y etiquetas (Open Geospatial Consortium (OGC), 2019, 2022; Ultralytics, 2026).

El conjunto resultante de imágenes GeoTIFF y archivos de anotación en formato YOLO constituyó el dataset base utilizado para la definición de las particiones de entrenamiento, validación y prueba, cuya organización y estrategia de validación cruzada se describen en la sección siguiente (Kohavi, 1995).

3.5. División de datos en *folds* de entrenamiento y validación

Con el dataset ya consolidado en términos espaciales y de anotaciones, el paso siguiente consistió en organizar los archivos en una estructura reproducible que permitiera aplicar validación cruzada (*k-fold*) (Kohavi, 1995) sin mezclar imágenes ni etiquetas, y manteniendo una separación clara entre datos de entrenamiento, validación y prueba (Kohavi, 1995).

El conjunto total estuvo compuesto por 169 parches de imagen en formato GeoTIFF (`.tif`), cada uno con su correspondiente archivo de anotación en formato YOLO (`.txt`). A partir de este conjunto se definieron dos niveles de partición bien diferenciados.

Por un lado, se reservó un **conjunto de prueba fijo** compuesto por 19 imágenes, junto con sus respectivos archivos `.txt`. Este conjunto se mantuvo constante a lo largo de todo el proceso y no participó en la generación de los *fold*s. La decisión de fijar un conjunto de prueba independiente permitió contar

con un bloque de datos estable, reutilizable en todas las corridas y no afectado por la rotación propia de la validación cruzada (Kohavi, 1995).

Por otro lado, las 150 imágenes restantes se utilizaron para construir 15 *folds*, cada uno compuesto por 10 imágenes. En cada iteración, un *fold* completo se destinó a validación, mientras que los 14 *folds* restantes se utilizaron como conjunto de entrenamiento. De este modo, cada imagen participó exactamente una vez como validación y el resto de las veces como entrenamiento, evitando sesgos asociados a una única partición (Kohavi, 1995).

Estructura de directorios por *fold*

Para cada *fold* se generó una carpeta independiente (`fold_i`) con una estructura de directorios compatible con la utilizada por YOLO (Ultralytics, 2026). Dentro de cada `fold_i` se definieron dos subdirectorios principales:

- `train/`, que contiene los datos utilizados para entrenamiento.
- `val/`, que contiene los datos utilizados para validación.

A su vez, tanto `train/` como `val/` se organizaron en dos subcarpetas:

- `images/`, donde se almacenan los parches de imagen en formato GeoTIFF (`.tif`);
- `labels/`, donde se almacenan los archivos de anotación en formato YOLO (`.txt`).

La organización se basó en una correspondencia estricta uno a uno entre imágenes y etiquetas: para cada archivo `.tif` presente en `images/` existe un archivo `.txt` con el mismo nombre base en `labels/`. Esta condición fue verificada durante la generación de los *folds*y resultó clave para evitar errores asociados a etiquetas faltantes o desalineadas (Ultralytics, 2026).

En cada carpeta de *fold* se incluyó además un archivo `data.yaml`, que define las rutas a los conjuntos de entrenamiento y validación correspondientes a esa partición. Este archivo actúa como descriptor del *fold* y permite cambiar de partición simplemente seleccionando el `data.yaml` adecuado, sin modificar el resto del *pipeline* (Ultralytics, 2026).

Separación del conjunto de prueba

El conjunto de prueba fijo se mantuvo completamente separado de la estructura de *fold*. Sus imágenes `.tif` y anotaciones `.txt` no aparecen en los directorios `train/` ni `val/` de ningún *fold*. Esta separación garantizó que las imágenes de prueba no influyan en la construcción de los *folds* y que su uso sea consistente a lo largo de todas las iteraciones (Kohavi, 1995).

En síntesis, esta organización permitió disponer de un esquema claro y reproducible: cada `fold_i` encapsula su propia partición de entrenamiento y validación con imágenes y etiquetas alineadas, mientras que el conjunto de prueba permanece fijo y desacoplado. Esta estructura dejó el dataset listo para su utilización sistemática en las etapas posteriores del trabajo (Kohavi, 1995; Ultralytics, 2026).

3.5. DIVISIÓN DE DATOS EN *FOLDS* DE ENTRENAMIENTO Y VALIDACIÓN

La Figura 3.11 presenta el *pipeline* completo seguido en este trabajo, detallando de forma integral el proceso de adquisición de datos, detección y segmentación de objetos, etiquetado, generación del dataset y validación final. Este esquema permite visualizar de manera ordenada y secuencial las distintas etapas involucradas en la construcción del conjunto de datos utilizado.

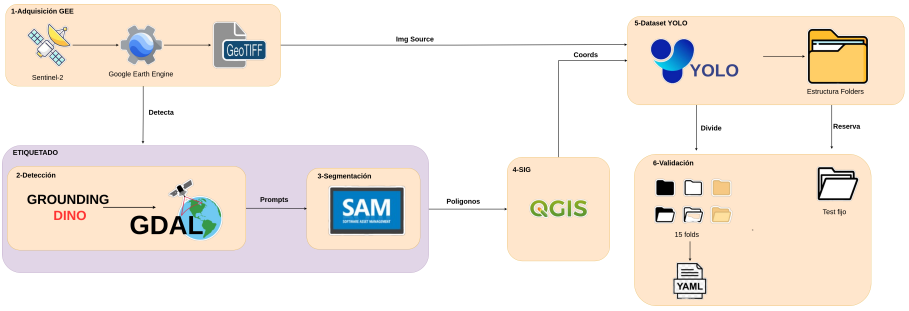

Figura 3.11: Pipeline completo de procesamiento de datos, detección, segmentación, etiquetado y validación

Capítulo 4

Resultados

4.1. Visión general de los resultados

En este capítulo presentamos los resultados obtenidos por el modelo durante el entrenamiento y la evaluación final. El análisis se basa en las curvas Precisión–Recall (PR), que evaluamos para distintos umbrales de *Intersection over Union (IoU)* y para diferentes composiciones espectrales de entrada (Powers, 2011).Las curvas PR nos permiten analizar de manera conjunta dos aspectos centrales del desempeño del modelo:

- **Calidad de detección**: analizamos qué tan bien el modelo identifica los pivotes reales sin generar falsos positivos, lo cual se refleja principalmente en la PR, definida como la proporción de detecciones correctas sobre el total de detecciones realizadas (Powers, 2011).
- **Calidad geométrica**: evaluamos qué tan precisa es la delimitación del contorno del pivote en las máscaras generadas, analizada indirectamente a través del Recall (REC) bajo distintos umbrales de IoU, donde valores más altos de IoU exigen una mayor coincidencia espacial entre la máscara predicha y la referencia (Everingham, 2010).

4.2. Análisis por umbral de IoU

En la Figura 4.1 se muestran las curvas PR, donde el eje vertical corresponde a la Precision (PREC) y el eje horizontal al REC. Cada panel corresponde a un umbral distinto de IoU: 0.75, 0.80, 0.85 y 0.90. Los colores representan las distintas composiciones espectrales evaluadas, mientras que los estilos de línea permiten diferenciarlas visualmente dentro de cada panel.

1. **IoU ≥ 0.75: criterio moderado.**

   Para IoU ≥ 0.75, representado en el panel superior izquierdo de la Figura 4.1, observamos que las curvas de todas las composiciones espectrales se mantienen muy próximas entre sí y presentan valores de PREC cercanos a 1 hasta niveles elevados de REC. Esto indica que, bajo un criterio de superposición moderado, el modelo recupera una gran cantidad de pivotes reales sin introducir un número significativo de falsos positivos. En este

régimen, el modelo identifica correctamente la presencia y la localización general del pivote, aun cuando existan pequeños errores en los bordes de la máscara.

2. **IoU ≥ 0.80 e IoU ≥ 0.85: mayor exigencia espacial.**

   Al aumentar el umbral a IoU ≥ 0.80, representado en el panel superior derecho de la Figura 4.1, y a IoU ≥ 0.85, representado en el panel inferior izquierdo, se observa una reducción gradual del REC máximo alcanzable. Si bien la PREC se mantiene elevada en las detecciones más confiables, algunas instancias dejan de cumplir con el criterio geométrico más estricto. Este comportamiento refleja que el modelo continúa detectando correctamente los pivotes, pero no siempre logra ajustar con precisión el contorno cuando se exige una coincidencia espacial elevada.

3. **IoU ≥ 0.90: criterio estricto.**

   Para IoU ≥ 0.90, mostrado en el panel inferior derecho de la Figura 4.1, se identifica una caída mucho más marcada del REC y diferencias más claras entre composiciones espectrales. Esto indica que solo los casos con bordes bien definidos y alto contraste logran cumplir con este criterio. Las detecciones afectadas por nubes, sombras, heterogeneidad del cultivo o bordes difusos son penalizadas fuertemente, lo cual resulta esperable dado el nivel de exigencia geométrica impuesto (Everingham, 2010).

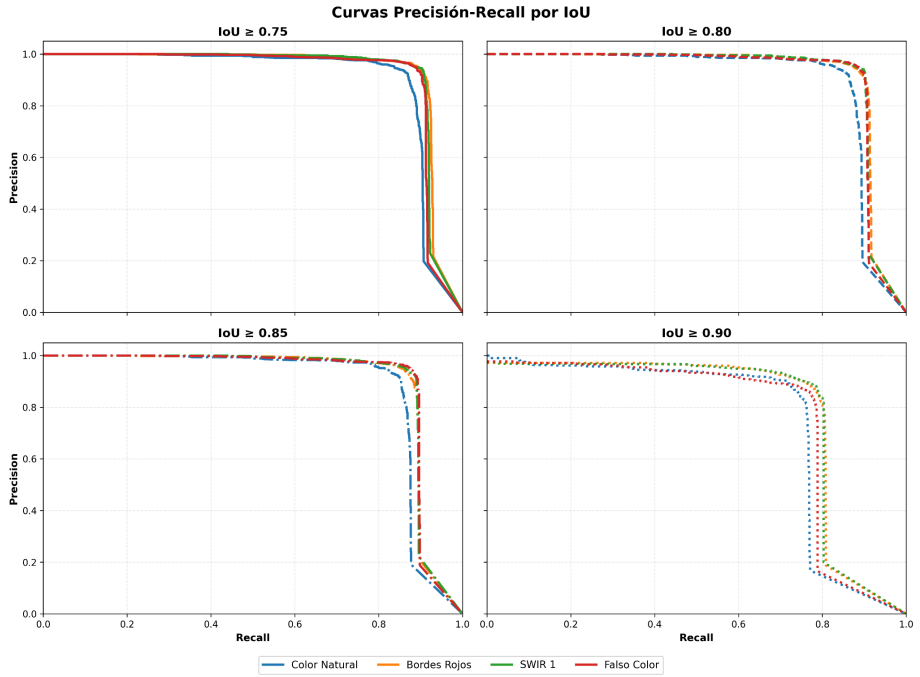

Figura 4.1: Curvas PR comparadas por umbral de IoU para distintas composiciones espectrales. Cada panel corresponde a un umbral de evaluación diferente: IoU ≥ 0.75 en el panel superior izquierdo, IoU ≥ 0.80 en el panel superior derecho, IoU ≥ 0.85 en el panel inferior izquierdo e IoU ≥ 0.90 en el panel inferior derecho. El eje horizontal representa el REC y el eje vertical la PREC. Los colores identifican las composiciones espectrales evaluadas: azul para color natural, naranja para bordes rojos, verde para Shortwave Infrared (SWIR) y rojo para falso color. Los estilos de línea identifican el umbral de IoU: línea continua para 0.75, línea discontinua para 0.80, línea punto-raya para 0.85 y línea punteada para 0.90.

4.3. Análisis por composición espectral

Por su parte, la Figura 4.2 permite analizar el comportamiento del modelo según la composición espectral utilizada. En este caso, cada panel corresponde a una composición espectral distinta, mientras que dentro de cada panel se comparan los distintos umbrales de IoU. A medida que el criterio geométrico se vuelve más estricto, las curvas tienden a disminuir su REC, lo que indica que algunas detecciones dejan de cumplir con los niveles más exigentes de superposición espacial.

1. **Color natural (B4, B3, B2).**

   En el panel superior izquierdo de la Figura 4.2, correspondiente a color natural, observamos que esta composición presenta un buen desempeño para valores moderados de IoU, pero constituye una de las composiciones más sensibles al aumento de la exigencia geométrica. Para valores altos de IoU, especialmente en la curva punteada correspondiente a 0.90, el

REC disminuye más rápidamente. Esto indica dificultades para ajustar con precisión los bordes cuando se utiliza únicamente información del espectro visible (Davis and Goadrich, 2006).

2. **Bordes rojos (Red Edge) (B7, B6, B5).**

   En el panel superior derecho de la Figura 4.2, correspondiente a bordes rojos, observamos que esta composición presenta un comportamiento más estable frente al incremento del umbral de IoU. Las curvas se mantienen con valores elevados de PREC durante gran parte del rango de REC, y la degradación del desempeño resulta más gradual. Esto sugiere una segmentación más coherente de los contornos, probablemente debido a la información adicional relacionada con la estructura de la vegetación que aporta esta región espectral (Delegido, 2011).

3. **SWIR (B11, B8, B4).**

   En el panel inferior izquierdo de la Figura 4.2, correspondiente a la composición SWIR, identificamos que esta constituye una de las composiciones más robustas. Mantiene valores elevados tanto de PREC como de REC incluso para umbrales altos de IoU. Esto indica una mejor delimitación geométrica del pivote. Atribuimos este comportamiento a la sensibilidad de esta banda a la humedad del suelo y a las diferencias entre áreas regadas y no regadas, que generan contrastes más definidos.

4. **Falso color (B8A, B4, B3).**

   En el panel inferior derecho de la Figura 4.2, correspondiente a falso color, observamos que esta composición presenta un desempeño intermedio. Funciona adecuadamente para valores moderados de IoU, pero su rendimiento cae cuando se exige una coincidencia geométrica estricta, especialmente para IoU ≥ 0.90. Esto sugiere una mayor variabilidad en el ajuste de los bordes respecto de composiciones como SWIR.

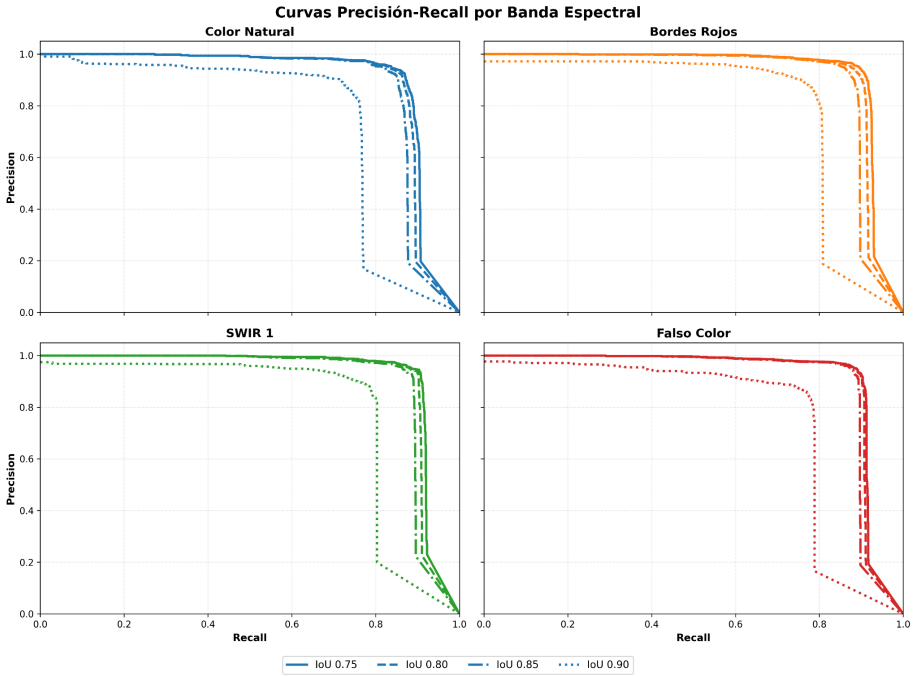

Figura 4.2: Curvas PR por composición espectral, comparando distintos umbrales de IoU. Cada panel corresponde a una composición espectral diferente: color natural en el panel superior izquierdo, bordes rojos en el panel superior derecho, SWIR en el panel inferior izquierdo y falso color en el panel inferior derecho. El eje horizontal representa el REC y el eje vertical la PREC. Los colores identifican la composición espectral de cada panel: azul para color natural, naranja para bordes rojos, verde para SWIR y rojo para falso color. Los estilos de línea representan los distintos umbrales de IoU: línea continua para 0.75, línea discontinua para 0.80, línea punto-raya para 0.85 y línea punteada para 0.90.

En conjunto, nuestros resultados muestran que el modelo alcanza un desempeño elevado en términos de precisión y cobertura para criterios geométricos moderados. Al aumentar el IoU, observamos que la precisión se mantiene relativamente estable, pero el REC disminuye, lo que indica que las principales limitaciones del modelo se asocian al refinamiento geométrico de los contornos y no a la detección del objeto.

Desde el punto de vista práctico, concluimos lo siguiente:

- Para aplicaciones que priorizan maximizar la detección de pivotes, consideramos adecuada cualquier composición espectral con IoU ≥ 0.75.
- Para aplicaciones que requieren alta precisión geométrica, identificamos a SWIR y a las bandas de Bordes Rojos como las opciones más robustas, especialmente para IoU ≥ 0.85.
- Cuando solo disponemos de información del espectro visible, concluimos que el color natural ofrece resultados aceptables, aunque con limitaciones claras para valores elevados de IoU.

4.4. Análisis con REC fijo

Con el objetivo de realizar una comparación cuantitativa directa entre configuraciones, fijamos el valor de REC en 0.80 y analizamos la precisión alcanzada bajo distintos umbrales de IoU y composiciones espectrales. Este criterio nos permite evaluar el comportamiento del modelo en un escenario operativo realista, en el cual priorizamos recuperar al menos el 80 % de los pivotes reales y analizamos el costo asociado en términos de falsos positivos y calidad geométrica de las segmentaciones.

4.4.1. Precisión en función del umbral de IoU

En esta sección analizamos la PREC alcanzada por el modelo al fijar el REC en 0.80 y comparar distintos umbrales de IoU. Este análisis permite evaluar cómo cambia el desempeño de las composiciones espectrales cuando se incrementa la exigencia geométrica entre la máscara predicha y la máscara de referencia. En la Figura 4.3, la línea vertical gris indica el punto de REC = 0.80, y los valores de precisión asociados se resumen en la Tabla 4.1.

1. **IoU** ≥ 0.75**.**

   En el panel superior izquierdo de la Figura 4.3, correspondiente a IoU $\geq$ 0.75, observamos que todas las composiciones espectrales alcanzan valores de PREC elevados y muy similares cuando el REC se fija en 0.80. Como se observa en la Tabla 4.1, la mediana de precisión es de 0.976, lo que indica un desempeño consistente bajo un criterio geométrico moderado. En este caso, las curvas se mantienen próximas a la región superior de la gráfica, lo que evidencia una baja presencia de falsos positivos. Esto sugiere que, para este nivel de exigencia, el modelo logra recuperar la mayoría de los pivotes reales sin que la composición espectral utilizada genere diferencias marcadas en el desempeño.

2. **IoU** ≥ 0.80 **e IoU** ≥ 0.85**.**

   En el panel superior derecho de la Figura 4.3, correspondiente a IoU $\geq$ 0.80, y en el panel inferior izquierdo, correspondiente a IoU $\geq$ 0.85, observamos que la PREC se mantiene elevada para todas las composiciones espectrales al fijar el REC en 0.80. Como se detalla en la Tabla 4.1, las medianas alcanzan valores de 0.975 y 0.971, respectivamente, lo que muestra que el modelo conserva un buen desempeño incluso cuando aumenta la exigencia espacial.

   Sin embargo, en estos paneles comienzan a observarse diferencias más claras entre composiciones. Las curvas correspondientes a SWIR y bordes rojos mantienen valores de precisión más estables, mientras que color natural presenta una disminución algo más marcada, especialmente para IoU $\geq$ 0.85. Este comportamiento indica que, aunque el modelo sigue detectando correctamente los pivotes, algunas composiciones espectrales favorecen una delimitación geométrica más precisa del contorno.

3. **IoU** ≥ 0.90**.**

   En el panel inferior derecho de la Figura 4.3, correspondiente a IoU ≥ 0.90, observamos una caída más marcada de la PREC al mantener fijo el REC

en 0.80. Como se presenta en la Tabla 4.1, la mediana desciende a 0.780, lo que refleja el carácter estricto de este criterio geométrico. A diferencia de los paneles anteriores, en este caso las diferencias entre composiciones espectrales son más evidentes.

En particular, SWIR alcanza el mayor valor de precisión, con 0.837, seguido por bordes rojos, con 0.811. Falso color presenta un valor intermedio, con 0.748, mientras que color natural muestra la caída más pronunciada, con una precisión de 0.211. Estos valores, detallados en la Tabla 4.1, indican que, cuando se exige una coincidencia espacial muy alta entre la predicción y la máscara de referencia, las composiciones que aportan mayor contraste espectral permiten conservar mejor la precisión del modelo.

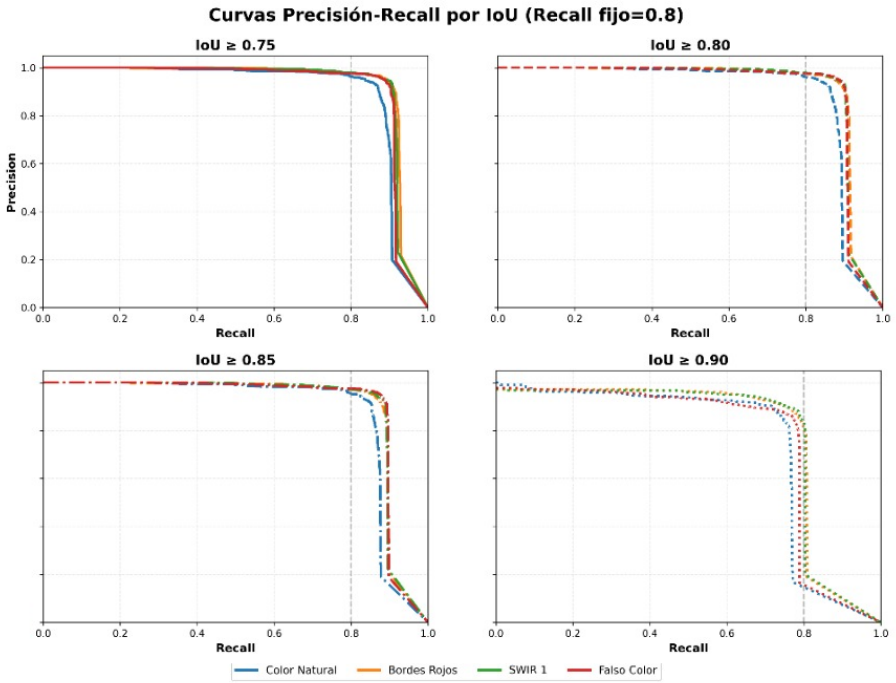

Figura 4.3: Curvas PR comparadas por umbral de IoU con REC fijo en 0.80. Cada panel corresponde a un umbral de evaluación diferente: IoU $\geq$ 0.75 en el panel superior izquierdo, IoU $\geq$ 0.80 en el panel superior derecho, IoU $\geq$ 0.85 en el panel inferior izquierdo e IoU $\geq$ 0.90 en el panel inferior derecho. El eje horizontal representa el REC y el eje vertical la PREC. Los colores identifican las composiciones espectrales evaluadas: azul para color natural, naranja para bordes rojos, verde para SWIR y rojo para falso color. Los estilos de línea identifican el umbral de IoU: línea continua para 0.75, línea discontinua para 0.80, línea punto-raya para 0.85 y línea punteada para 0.90. La línea vertical gris marca el valor de REC = 0.80 utilizado para comparar la precisión entre configuraciones.

En la Tabla 4.1 se presentan los valores de PREC obtenidos en el punto de REC = 0.80 para cada composición espectral y cada umbral de IoU. Cada

fila corresponde a un nivel de exigencia geométrica distinto, mientras que las columnas permiten comparar el desempeño de las composiciones espectrales evaluadas.

Tabla 4.1: Precisión alcanzada por cada composición espectral para un REC fijo de 0.80, según el umbral de IoU utilizado.

Umbral de IoU	Color natural	Bordes rojos	SWIR	Falso color	Mediana
0.75	0.964	0.977	0.979	0.976	0.976
0.80	0.961	0.975	0.978	0.976	0.975
0.85	0.953	0.971	0.971	0.974	0.971
0.90	0.211	0.811	0.837	0.748	0.780

4.4.2. Análisis por composición espectral con REC fijo en 0.80

En la Figura 4.4 se presentan las curvas Precisión–Recall para cada composición espectral, destacando el punto correspondiente a REC = 0.80. Este enfoque permite analizar, dentro de cada banda, cómo impacta el incremento del umbral de IoU en la precisión alcanzada cuando se exige recuperar el 80 % de los pivotes reales.

1. **Color natural (B4, B3, B2).**

   En el panel superior izquierdo de la Figura 4.4, correspondiente a color natural, observamos que esta composición mantiene una PREC elevada para IoU ≥ 0.75, ≥ 0.80 y ≥ 0.85. Como se detalla en la Tabla 4.2, los valores de precisión correspondientes son 0.964, 0.961 y 0.953, respectivamente. Sin embargo, cuando el umbral aumenta a IoU ≥ 0.90, la curva punteada muestra una caída marcada en el punto de REC = 0.80, con una precisión de 0.211.

   La mediana de precisión de esta composición es de 0.957, como se presenta en la Tabla 4.2. Este comportamiento indica que el color natural resulta adecuado bajo criterios geométricos moderados, pero presenta mayores limitaciones cuando se exige una coincidencia espacial muy estricta. Esto sugiere dificultades para ajustar con precisión los bordes del pivote cuando se utiliza únicamente información del espectro visible.

2. **Bordes rojos (Red Edge) (B7, B6, B5).**

   En el panel superior derecho de la Figura 4.4, correspondiente a bordes rojos, observamos un comportamiento más estable frente al aumento del umbral de IoU. Las curvas se mantienen próximas a la región superior de la gráfica hasta IoU ≥ 0.85, lo que indica una buena capacidad para conservar la precisión al fijar el REC en 0.80.

   Como se observa en la Tabla 4.2, esta composición alcanza valores de precisión de 0.977, 0.975 y 0.971 para IoU ≥ 0.75, ≥ 0.80 y ≥ 0.85, respectivamente. Para IoU ≥ 0.90, la precisión disminuye a 0.811, aunque esta reducción es menos pronunciada que la registrada en color natural. Asimismo, su mediana de precisión es de 0.973.

Estos resultados sugieren que las bandas de borde rojo permiten conservar mejor la precisión cuando se exige una mayor coincidencia geométrica entre la máscara predicha y la máscara de referencia.

3. **SWIR (B11, B8, B4).**

   En el panel inferior izquierdo de la Figura 4.4, correspondiente a SWIR, identificamos el comportamiento más robusto entre las composiciones evaluadas. Las curvas mantienen valores elevados de PREC para los distintos umbrales de IoU, incluso bajo el criterio más estricto.

   De acuerdo con la Tabla 4.2, esta composición alcanza valores de precisión de 0.979, 0.978 y 0.971 para IoU ≥ 0.75, ≥ 0.80 y ≥ 0.85, respectivamente. Para IoU ≥ 0.90, conserva una precisión de 0.837, correspondiente al valor más elevado entre las composiciones bajo este criterio. Además, presenta una mediana de precisión de 0.975.

   Este resultado sugiere que SWIR favorece una mejor delimitación geométrica del pivote, probablemente por el contraste que aporta entre áreas regadas y no regadas. En consecuencia, esta composición permite sostener mejor la precisión cuando se exige una coincidencia espacial elevada.

4. **Falso color (B8A, B4, B3).**

   En el panel inferior derecho de la Figura 4.4, correspondiente a falso color, observamos un desempeño elevado para umbrales moderados y altos de IoU. Las curvas se mantienen estables hasta IoU ≥ 0.85, con un comportamiento comparable al de bordes rojos y SWIR.

   Como se presenta en la Tabla 4.2, esta composición alcanza valores de precisión de 0.976, 0.976 y 0.974 para IoU ≥ 0.75, ≥ 0.80 y ≥ 0.85, respectivamente. Para IoU ≥ 0.90, la precisión disminuye a 0.748, aunque se mantiene por encima de la observada en color natural. Su mediana de precisión es de 0.975, igual a la obtenida por SWIR.

   Esto indica un comportamiento intermedio: el falso color conserva buenos niveles de precisión bajo exigencias moderadas, pero no alcanza la robustez de SWIR ni de bordes rojos bajo el umbral más estricto.

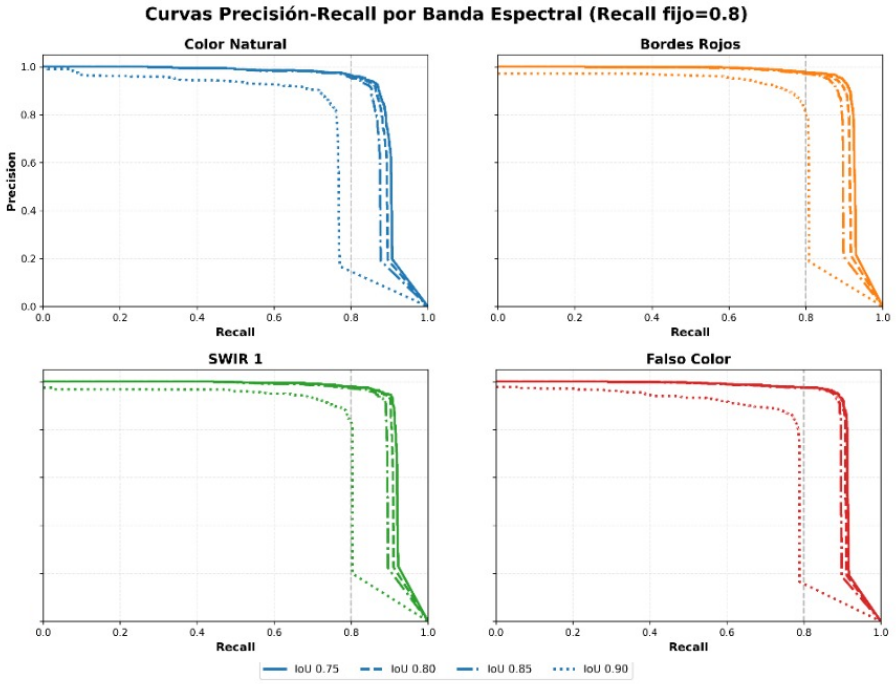

Figura 4.4: Curvas PR por composición espectral con REC fijo en 0.80. Cada panel corresponde a una composición espectral diferente: color natural en el panel superior izquierdo, bordes rojos en el panel superior derecho, SWIR en el panel inferior izquierdo y falso color en el panel inferior derecho. El eje horizontal representa el REC y el eje vertical la PREC. Los colores identifican la composición espectral de cada panel: azul para color natural, naranja para bordes rojos, verde para SWIR y rojo para falso color. Los estilos de línea representan los distintos umbrales de IoU: línea continua para 0.75, línea discontinua para 0.80, línea punto-raya para 0.85 y línea punteada para 0.90. La línea vertical gris marca el valor de REC = 0.80 utilizado para comparar la precisión entre configuraciones.

Los valores correspondientes al punto de REC = 0.80 se presentan en la Tabla 4.2. En conjunto, los resultados muestran que todas las composiciones espectrales mantienen una PREC elevada hasta IoU $\geq$ 0.85. Las diferencias más importantes aparecen bajo el criterio más estricto, IoU $\geq$ 0.90, donde SWIR y bordes rojos sostienen los mejores valores, mientras que color natural presenta la caída más pronunciada.

Tabla 4.2: Precisión alcanzada por cada composición espectral para un REC fijo de 0.80, considerando distintos umbrales de IoU.

Composición espectral	**IoU $\geq$ 0.75**	**IoU $\geq$ 0.80**	**IoU $\geq$ 0.85**	**IoU $\geq$ 0.90**	**Mediana**
Color natural	0.964	0.961	0.953	0.211	0.957
Bordes rojos	0.977	0.975	0.971	0.811	0.973
SWIR	0.979	0.978	0.971	0.837	0.975
Falso color	0.976	0.976	0.974	0.748	0.975

En conjunto, la Figura 4.4 evidencia que las diferencias entre composiciones espectrales se vuelven más relevantes a medida que aumenta la exigencia geométrica. Para umbrales de IoU de hasta 0.85, todas las configuraciones mantienen un desempeño confiable y valores elevados de PREC. Sin embargo, bajo el criterio más estricto, IoU ≥ 0.90, las composiciones SWIR y, en menor medida, bordes rojos muestran una ventaja clara, ya que logran sostener mejor la precisión cuando se requiere una coincidencia espacial más precisa entre la máscara predicha y la máscara de referencia.

Estos resultados indican que la principal limitación del modelo no radica en la detección del objeto, sino en el refinamiento geométrico de las máscaras. La elección de la composición espectral adquiere relevancia únicamente cuando se demanda una segmentación de alta precisión.

Capítulo 5

Conclusiones y trabajo a futuro

En este trabajo se evaluó el rendimiento de distintas combinaciones espectrales de Sentinel-2 para la detección automática de áreas irrigadas por pivotes centrales.

El punto de partida fue la adquisición de imágenes Sentinel-2 a través de Google Earth Engine. Se trabajó sobre la provincia de Córdoba durante la campaña primavera–verano 2023–2024, un período seleccionado por corresponder a la etapa de mayor crecimiento y desarrollo de los cultivos extensivos en la región. En esta fase fenológica, el contraste espectral entre áreas irrigadas y no irrigadas se ve intensificado por la actividad fotosintética y la cobertura vegetal activa.

Para cada zona de interés se generaron cuatro composiciones espectrales: color natural (B4, B3, B2), borde rojo (B7, B6, B5), falso color (B8A, B4, B3) y SWIR (B11, B8, B4). Cada una fue diseñada para resaltar distintas propiedades biofísicas, como el vigor de la vegetación, el contenido hídrico del suelo y la actividad fotosintética, entre otras. Estas composiciones se exportaron como parches georreferenciados en formato GeoTIFF, listos para su posterior procesamiento.

Posteriormente, se utilizó Grounding DINO para construir el dataset, localizando estructuras circulares en las imágenes a partir de descripciones textuales. Las detecciones obtenidas se pasaron a SAM, que generó máscaras de segmentación precisas para cada pivote detectado. El resultado fueron pseudo-etiquetas de buena calidad, generadas sin intervención manual directa.

Para asegurar que cada detección estuviera correctamente ubicada y alineada con su parche de origen, todo el proceso se integró en QGIS. Allí se cargaron las máscaras raster junto con las imágenes originales, se verificó la correspondencia espacial píxel a píxel, se vectorizaron las detecciones mediante GDAL Polygonize y se consolidaron en una capa vectorial maestra con campos de trazabilidad. Este trabajo permitió inspeccionar visualmente los resultados, descartar detecciones erróneas y garantizar que las anotaciones finales mantuvieran la referencia espacial original, estandarizada en el sistema POSGAR 98, Faja 4.

Con la capa vectorial validada, se generaron las anotaciones en formato YOLO mediante scripts en Python que cruzaron la información geométrica de los polígonos con la extensión espacial de cada parche. Los 169 parches resultan-

tes se organizaron en 15 *folds* de entrenamiento y validación, más un conjunto de prueba fijo de 19 imágenes que nunca participó del entrenamiento. Esta estructura permitió evaluar el modelo mediante validación cruzada, obteniendo estimaciones de desempeño más confiables que las que proporcionaría una única partición de los datos.

Finalmente, se entrenó el modelo YOLO11s-seg de forma independiente sobre cada una de las cuatro composiciones espectrales, manteniendo la misma arquitectura, los mismos hiperparámetros y la misma estructura de *folds* en todos los casos.

La evaluación de los resultados se realizó mediante curvas Precisión–Recall bajo cuatro umbrales de Intersection over Union (IoU) —0.75, 0.80, 0.85 y 0.90— , complementadas con un análisis de Precision (PREC) a Recall (REC) fijo en 0.80.

Para umbrales moderados de IoU, como 0.75 y 0.80, todas las composiciones espectrales alcanzaron valores de PREC cercanos a 1 en amplios rangos de REC, lo que indica que el modelo aprendió a reconocer los pivotes de riego de manera consistente, independientemente de la composición espectral utilizada. En otras palabras, cuando el modelo detecta un pivote, en la gran mayoría de los casos la detección corresponde efectivamente a un pivote real.

Las diferencias entre composiciones, en cambio, se vuelven más evidentes al aumentar la exigencia geométrica. Todas conservaron una precisión elevada hasta IoU $\geq$ 0.85 —superando el 95 % de precisión al recuperar el 80 % de los pivotes reales—, lo que muestra que el modelo detecta adecuadamente la presencia y ubicación de los pivotes bajo criterios geométricos moderados y altos.

Sin embargo, al utilizar IoU $\geq$ 0.90, criterio que exige una coincidencia mucho más precisa entre la máscara predicha y el contorno de referencia, las diferencias entre composiciones se hicieron mucho más marcadas. Con un REC fijo en 0.80, la composición Shortwave Infrared (SWIR) mostró el comportamiento más robusto frente a esta mayor exigencia; falso color y bordes rojos también mantuvieron un desempeño estable, mientras que color natural presentó la mayor disminución bajo el umbral más estricto.

Por lo tanto, cualquiera de las composiciones resulta adecuada cuando el objetivo es identificar la presencia y ubicación general de los pivotes. Para aplicaciones que requieren una delimitación más precisa de la superficie irrigada, se recomienda priorizar SWIR y, como alternativa, las bandas de bordes rojos. En síntesis, la composición espectral influye principalmente en la precisión con la que se delimitan los contornos, más que en la capacidad general del modelo para detectar los pivotes.

5.1. Trabajo a Futuro

Una posible extensión de este estudio es analizar composiciones espectrales adicionales a las cuatro evaluadas en este trabajo. Sentinel-2 ofrece 13 bandas que cubren desde el visible hasta el infrarrojo de onda corta, lo que abre un espacio amplio de combinaciones aún no estudiadas. Como línea futura se propone evaluar composiciones que incorporen índices espectrales derivados,como el NDVI, el NDWI o el NDMI, o combinaciones de bandas no convencionales, con el fin de determinar si existen configuraciones que mejoren la delimitación

geométrica de los pivotes, aspecto en el que se identificaron las principales limitaciones del modelo actual, especialmente para umbrales de IoU elevados.

En segundo lugar, resulta necesario evaluar el comportamiento del modelo en otros períodos temporales. Este trabajo se centró en la campaña primavera–verano 2023–2024, una ventana caracterizada por el máximo desarrollo vegetativo de los cultivos extensivos. No obstante, es importante señalar que el entrenamiento se realizó utilizando la mediana temporal del período completo, lo que implica que la información radiométrica utilizada corresponde a una síntesis estadística y no a estados fenológicos específicos.

En este sentido, sería relevante analizar imágenes correspondientes a fechas concretas dentro de la campaña, representativas de distintos estados fenológicos (siembra, crecimiento activo, madurez o postcosecha), con el fin de evaluar la sensibilidad del modelo ante variaciones intraanuales más marcadas. Asimismo, extender el análisis a estaciones como otoño o invierno permitiría estudiar escenarios donde el contraste espectral disminuye o los pivotes se encuentran inactivos.

Incorporar múltiples campañas agrícolas posibilitaría analizar la estabilidad temporal de las detecciones y evaluar la capacidad de generalización del modelo bajo diferentes condiciones radiométricas. Como extensión natural, podría explorarse la clasificación del tipo de cultivo asociado a cada pivote, integrando información espectral y temporal para avanzar hacia un sistema no solo de detección estructural, sino también de caracterización productiva.

En tercer lugar, se propone ampliar el área de estudio más allá de la región analizada en la provincia de Córdoba. Los pivotes centrales se distribuyen en diversas regiones de Argentina, como el sur de Buenos Aires, el este de San Luis o el norte de La Pampa y en numerosos países a nivel mundial, en diferentes regímenes de suelo y clima, tipos de cultivo y patrones de uso del suelo muy variados. Aplicar el modelo entrenado a estas nuevas áreas sin re-entrenamiento permitiría evaluar su capacidad de transferencia espacial y detectar en qué condiciones su desempeño se degrada.

Bibliografía

Agrivi (2020). Center Pivot Irrigation: Components and advantages. Agrivi Knowledge Base. Consultado en 2025.

AGRIVI (2025). Center pivot system: an efficient and economical solution for irrigation. https://www.agrivi.com/blog/center-pivot-system-an-efficient-and-economical-solution-for-irrigation/. Accedido en diciembre de 2025.

Atkinson, P. M. and Tatnall, A. R. L. (1997). Introduction: neural networks in remote sensing. *International Journal of Remote Sensing*, 18(4):699–709.

Barrios, J. (2020). La matriz de confusión y sus métricas. Consultado en 2025.

Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Springer.

Camacho-Velasco, M. . o. (2015). *Introducción al sensado remoto*. Editorial Académica, Ciudad.

Cifuentes, A., Mendoza, E., Lizcano, M., Santrich, A., and Moreno-Trillos, S. (2019). Desarrollo de una red neuronal convolucional para reconocer patrones en imágenes. *Investigación y Desarrollo en TIC*, 10(2):7–17.

Climate FieldView Argentina (2022). Genética y fieldview para enfrentar a la sequía en argentina. https://blog.climatefieldview.com.ar/genetica-y-fieldview-para-enfrentar-sequia-en-argentina. Accedido: 2026-01-05.

Cortijo, F. J. (2001). *Riego y drenaje: fundamentos y aplicaciones*. Mundi-Prensa, Madrid, 1 edition.

Cursos Teledetección (2020). Combinación de bandas en imágenes sentinel-2. https://www.cursosteledeteccion.com/combinacion-de-bandas-en-imagenes-sentinel2/. Consultado en 2025.

Davis, J. and Goadrich, M. (2006). The relationship between precision-recall and roc curves. *Proceedings of the 23rd International Conference on Machine Learning*.

Delegido, J. e. a. (2011). Evaluation of sentinel-2 red-edge bands for empirical estimation of green lai. *Remote Sensing of Environment*.

Drusch, M., Del Bello, U., Carlier, S., Colin, O., Fernandez, V., Gascon, F., Hoersch, B., Isola, C., Laberinti, P., Martimort, P., et al. (2012a). Sentinel-2: Esa's optical high-resolution mission for gmes operational services. *Remote Sensing of Environment*, 120:25–36.

Drusch, M., Del Bello, U., Carlier, S., Colin, O., Fernandez, V., Gascon, F., Hoersch, B., Isola, C., Laberinti, P., Martimort, P., Meygret, A., Spoto, F., Sy, O., Marchese, F., and Bargellini, P. (2012b). Sentinel-2: Esa's optical high-resolution mission for gmes operational services. *Remote Sensing of Environment*, 120:25–36.

EPSG Geodetic Parameter Dataset (2024). Epsg:22174 — posgar 98 / argentina 3.

Everingham, M. e. a. (2010). The pascal visual object classes (voc) challenge. *International Journal of Computer Vision*.

FAO (2011). *The State of the World's Land and Water Resources for Food and Agriculture (SOLAW)*. Food and Agriculture Organization of the United Nations, Rome.

Food and Agriculture Organization of the United Nations (2021). The state of the world's land and water resources for food and agriculture: Systems at breaking point.

Garcia-Garcia, A. et al. (2018). A review on deep learning techniques applied to semantic segmentation. *arXiv preprint arXiv:1704.06857*.

GDAL/OSGeo (2025a). Gdal: gdal_translate. `https://gdal.org/en/latest/programs/gdal_translate.html`. Accedido en 2026-01-05.

GDAL/OSGeo (2025b). Gdal: Polygonize (raster to vector). `https://gdal.org/en/latest/development/rfc/rfc59.1_utilities_as_a_library.html`. Accedido en 2026-01-05.

Geoinnova (2020). Composiciones rgb de imágenes satélite. Consultado en 2025.

GIS Geography (2020). Sentinel-2 bands and combinations.

Goodfellow, I., Bengio, Y., and Courville, A. (2016). *Deep Learning*. MIT Press.

Gorelick, N., Hancher, M., Dixon, M., Ilyushchenko, S., Thau, D., and Moore, R. (2017a). Google earth engine: Planetary-scale geospatial analysis for everyone. *Remote Sensing of Environment*, 202:18–27.

Gorelick, N., Hancher, M., Dixon, M., Ilyushchenko, S., Thau, D., and Moore, R. (2017b). Google earth engine: Planetary-scale geospatial analysis for everyone. *Remote Sensing of Environment*, 202:18–27.

He, K., Gkioxari, G., Dollár, P., and Girshick, R. (2017). Mask r-cnn. In *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*.

Herrera, E. R. and Correa, J. T. (2005). Evaluación técnica y económica de un sistema de riego por pivote central. *Agro Sur*, 33(2):62–73.

Instituto Nacional de Tecnología Agropecuaria (2011). Riego por pivote central: experiencias y recomendaciones.

Irrifrance (s.f.). Pivot irrifrance. `https://es.scribd.com/document/375564421/PIVOT-IRRIFRANCE`. Documento consultado en Scribd.

Jensen, J. R. (2015). *Remote Sensing of the Environment: An Earth Resource Perspective*. Pearson, Upper Saddle River, NJ, 2 edition.

Kirillov, A., Mintun, E., Ravi, N., Mao, H., Rolland, C., et al. (2023). Segment anything. *arXiv preprint arXiv:2304.02643*.

Kohavi, R. (1995). A study of cross-validation and bootstrap for accuracy estimation and model selection. In *Proceedings of the 14th International Joint Conference on Artificial Intelligence (IJCAI)*.

Krizhevsky, A., Sutskever, I., and Hinton, G. (2012). Imagenet classification with deep convolutional neural networks. *Advances in Neural Information Processing Systems*.

Li, S., Zhang, L., and Ding, X. (2019). Deep learning for remote sensing image classification: A survey. *Wiley Interdisciplinary Reviews: Data Mining and Knowledge Discovery*, 8(6):e1264.

Lillesand, T. M., Kiefer, R. W., and Chipman, J. W. (2015). *Remote Sensing and Image Interpretation*. Wiley, New York, 7 edition.

Liu, S., Zeng, Z., Ren, T., Li, F., Zhang, H., et al. (2023). Grounding dino: Marrying dino with grounded pre-training for open-set object detection. *arXiv preprint arXiv:2303.05499*.

Ma, Y., Wu, H., Wang, L., Huang, B., Ranjan, R., Zomaya, A., and Jie, W. (2015). Remote sensing big data computing: Challenges and opportunities. *Future Generation Computer Systems*, 51:47–60.

Martellotto, E., Salas, H., and Giubergia, J. (2005). Evaluación técnica y económica del riego por pivote central. *Agro Sur*, 33(2):62–73.

Minaee, S. et al. (2021). Image segmentation using deep learning: A survey. *IEEE Transactions on Pattern Analysis and Machine Intelligence*.

Mitchell, T. M. (1997). *Machine Learning*. McGraw-Hill.

Montesinos, P., Camacho, E., and Rodríguez, F. (2007). Aplicaciones de la automatización en el riego y la fertirrigación. *Revista RIA*, 33(2):45–56.

Nelson Irrigation Corporation (2025). Orchard irrigation. `https://nelsonirrigation.com/solutions/tree-and-vine/orchard-irrigation/`. Accedido en diciembre de 2025.

Open Geospatial Consortium (OGC) (2019). Ogc geotiff standard. `https://www.ogc.org/standard/geotiff/`. Accedido en 2026-01-05.

Open Geospatial Consortium (OGC) (2022). Ogc geopackage standard. `https://www.ogc.org/standard/geopackage/`. Accedido en 2026-01-05.

Phiri, D., Simwanda, M., Salekin, S., Nyirenda, V. R., Murayama, Y., and Ranagalage, M. (2020). Sentinel-2 data for land cover/use mapping: A review. *Remote Sensing*, 12(14):2291.

Powers, D. M. W. (2011). Evaluation: From precision, recall and f-measure to roc, informedness, markedness and correlation. *Journal of Machine Learning Technologies*.

Puroxi (2025). Water sprinkler for agriculture. `https://puroxi.com/water-sprinkler-for-agriculture/`. Accedido en diciembre de 2025.

Pérez, R. M., Arias, J. S., and Porras, A. M. (2019). Introducción al aprendizaje automático con yolo. *Tecnología Vital*, 2(6).

QGIS Project (2026). Qgis documentation (user manual). `https://docs.qgis.org/latest/en/docs/user_manual/`. Accedido en 2026-01-05.

Ren, S., He, K., Girshick, R., and Sun, J. (2015). Faster r-cnn: Towards real-time object detection with region proposal networks. *IEEE Transactions on Pattern Analysis and Machine Intelligence*.

ResearchGate (2020). Aerial view of a center pivot irrigation system. `https://www.researchgate.net/figure/Aerial-view-of-a-center-pivot-irrigation-system_fig1_338824831`. Accedido en diciembre de 2025.

Richards, J. A. (2013). *Remote Sensing Digital Image Analysis: An Introduction*. Springer, Berlin, 4 edition.

Roboflow / Community reference (2024). Yolov8 segmentation annotation format (polygons). `https://blog.roboflow.com/annotate-yolov8/`. Accedido en 2026-01-05.

Saraiva, M., Protas, , Salgado, M., and Souza Jr., C. (2020). Automatic mapping of center pivot irrigation systems from satellite images using deep learning. *Remote Sensing*, 12(3):558.

Scanlon, B. R., Faunt, C. C., Longuevergne, L., et al. (2012). Groundwater depletion and sustainability of irrigation in the us high plains and central valley. *Proceedings of the National Academy of Sciences*, 109(24):9320–9325.

Sentinel Hub (2021a). Sentinel-2 red edge bands explained.

Sentinel Hub (2021b). Swir band applications in sentinel-2.

SuperAnnotate (2021). Intersection over union for object detection. Consultado en 2025.

Thenkabail, P. S., Lyon, J. G., and Huete, A. (2012). *Hyperspectral Remote Sensing of Vegetation*. CRC Press, Boca Raton.

TRAXCO (2013). Cultivo de soja bajo pivot. `https://www.traxco.es/blog/produccion-agricola/cultivo-de-soja-bajo-pivot`. Accedido: 2026-01-05.

Ultralytics (2026). Ultralytics: Segmentation datasets (yolo-format polygons). `https://docs.ultralytics.com/datasets/segment/`. Accedido en 2026-01-05.

Verbesselt, J., Hyndman, R., Zeileis, A., and Culvenor, D. (2010). Phenological change detection while accounting for abrupt and gradual trends in satellite image time series. *Remote Sensing of Environment*, 114(12):2970–2980.

Wikipedia contributors (2025). Drip irrigation. `https://en.wikipedia.org/wiki/Drip_irrigation`. Accedido en diciembre de 2025.

Woodcock, C. E., Allen, R., Anderson, M., Belward, A., Bindschadler, R., Cohen, W. B., Gao, F., Goward, S. N., Helder, D., Hunt, E., et al. (2008). Free access to landsat imagery. *Remote Sensing of Environment*, 112(4):1913–1926.

Zhu, X. X., Tuia, D., Mou, L., Xia, G.-S., Zhang, L., Xu, F., and Fraundorfer, F. (2017). Deep learning in remote sensing: A comprehensive review and list of resources. *IEEE Geoscience and Remote Sensing Magazine*, 5(4):8–36. finalnamedelim¿2&